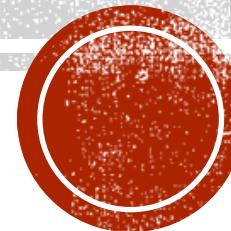


# یادگیری عمیق در تصاویر پزشکی

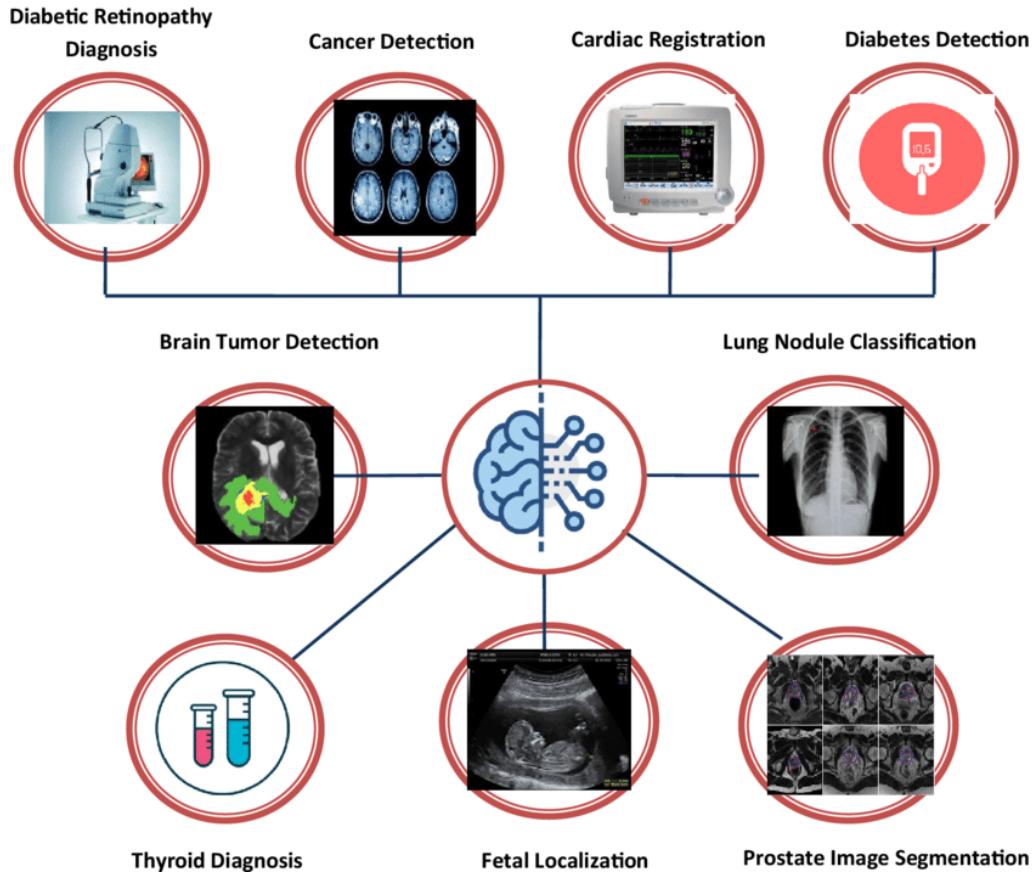
دکتر ملیحه ثابتی

استادیار گروه کامپیوتر دانشگاه آزاد اسلامی

واحد تهران شمال



# هوش مصنوعی در تصاویر پزشکی

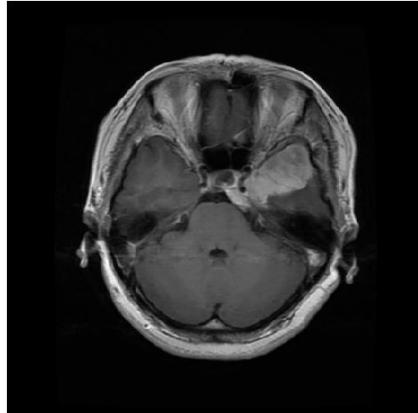


- دسته بندی تصاویر (Image classification)
- قطعه بندی تصاویر (Image segmentation)
- تولید تصاویر جدید (Image generation)

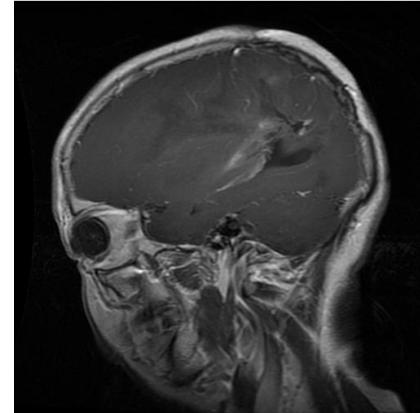
# دسته بندی تصاویر پزشکی

## Image classification ▪

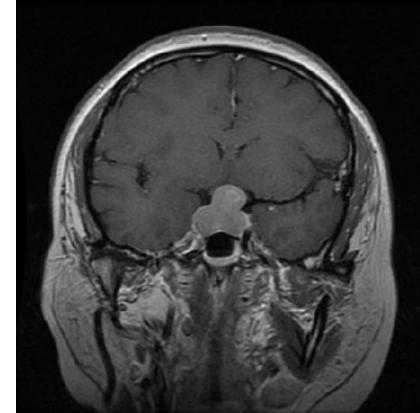
- یادگیری نظارت شده ای که متکی بر داده های ورودی و خروجی است و سعی می کند یک تابع جدا کننده برای نگاشت داده ها به مجموعه ای از برچسب ها را یاد بگیرد



meningiomas



gliomas

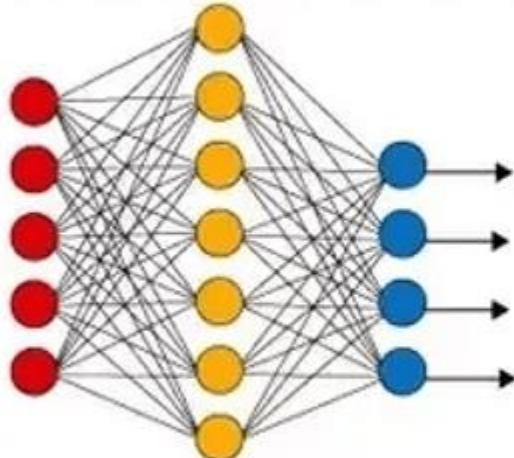


pituitary

# دسته بندی تصاویر پزشکی

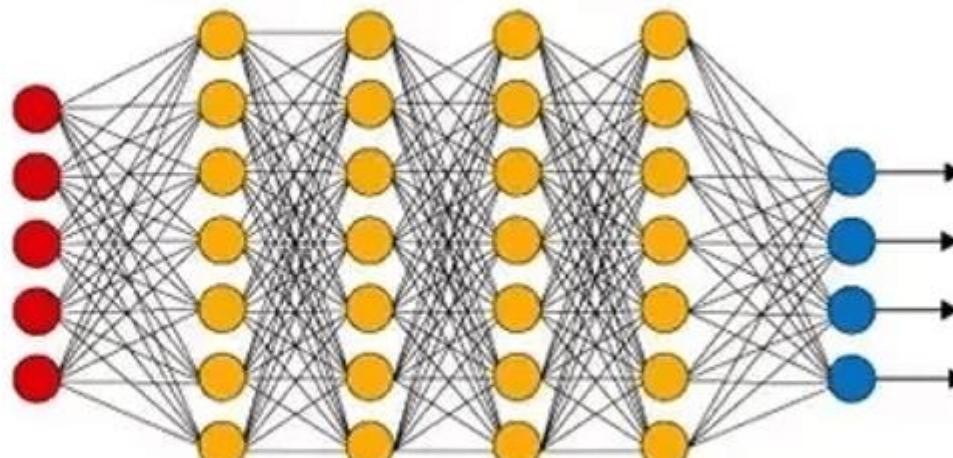
- شبکه عصبی عمیق از تعداد زیادی نرون تشکیل می شود (هر نرون یک واحد پردازش اطلاعات در نظر گرفته می شود) این شبکه می تواند از تصاویر unsupervised large-scale ویژگی هایی را استخراج نماید
- Convolutional neural network (CNN)

Simple Neural Network



● Input Layer

Deep Learning Neural Network

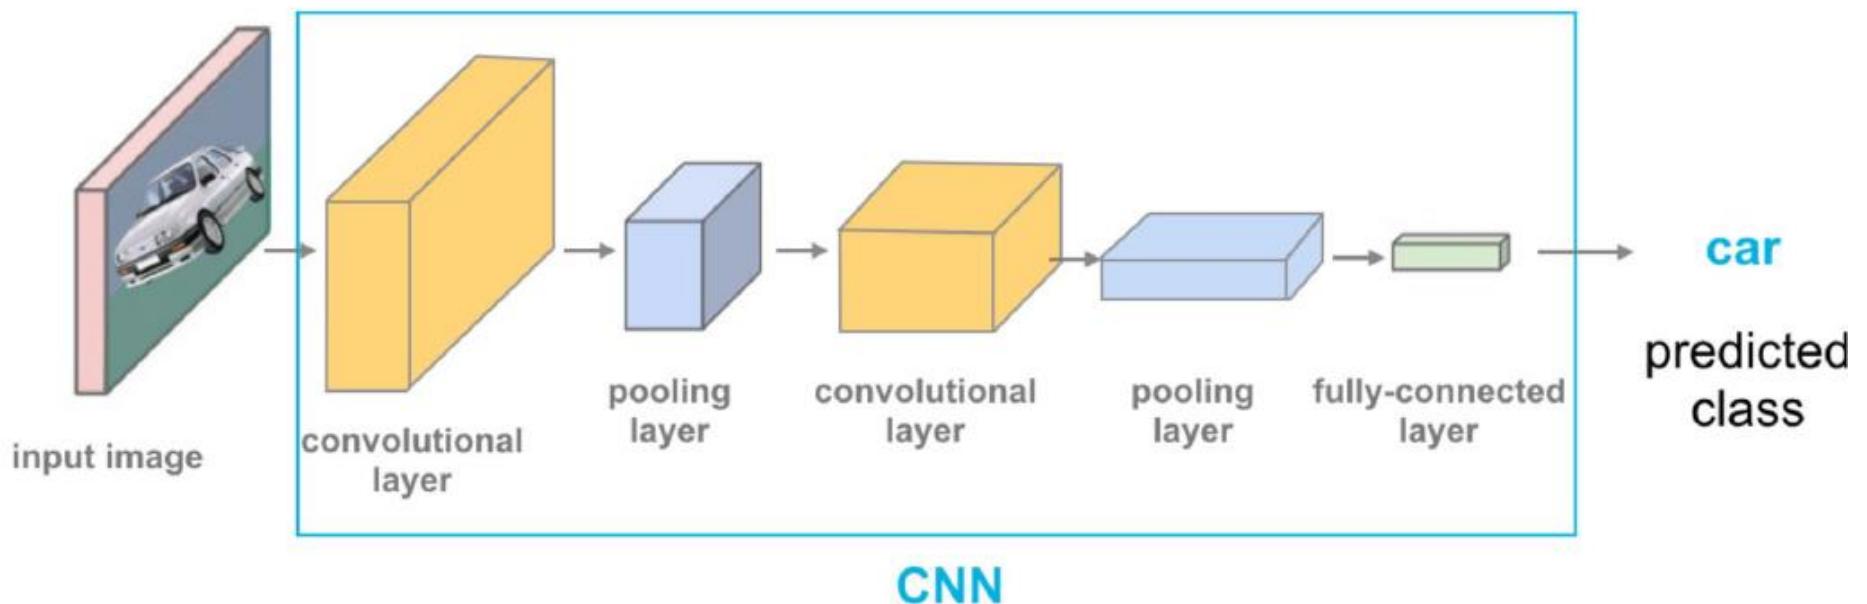


● Hidden Layer

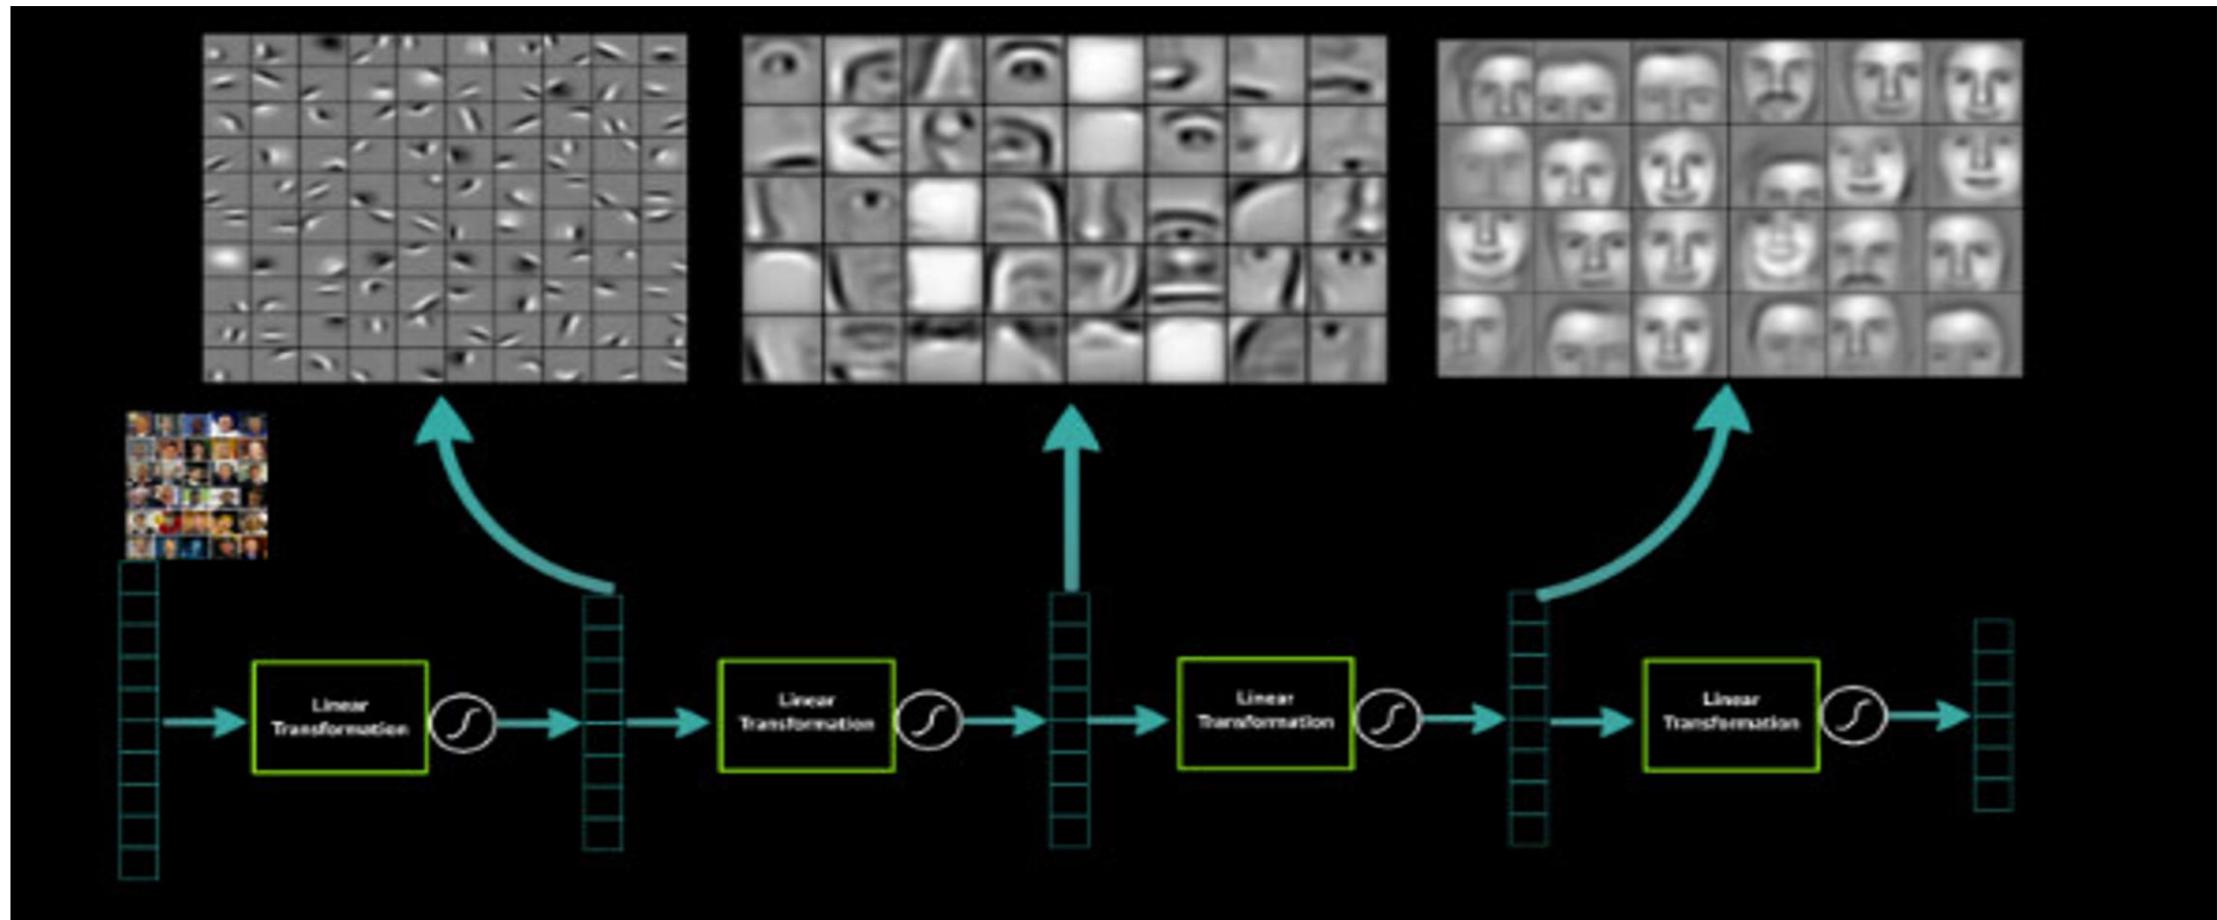
● Output Layer

# مقدمه‌ای بر CNN

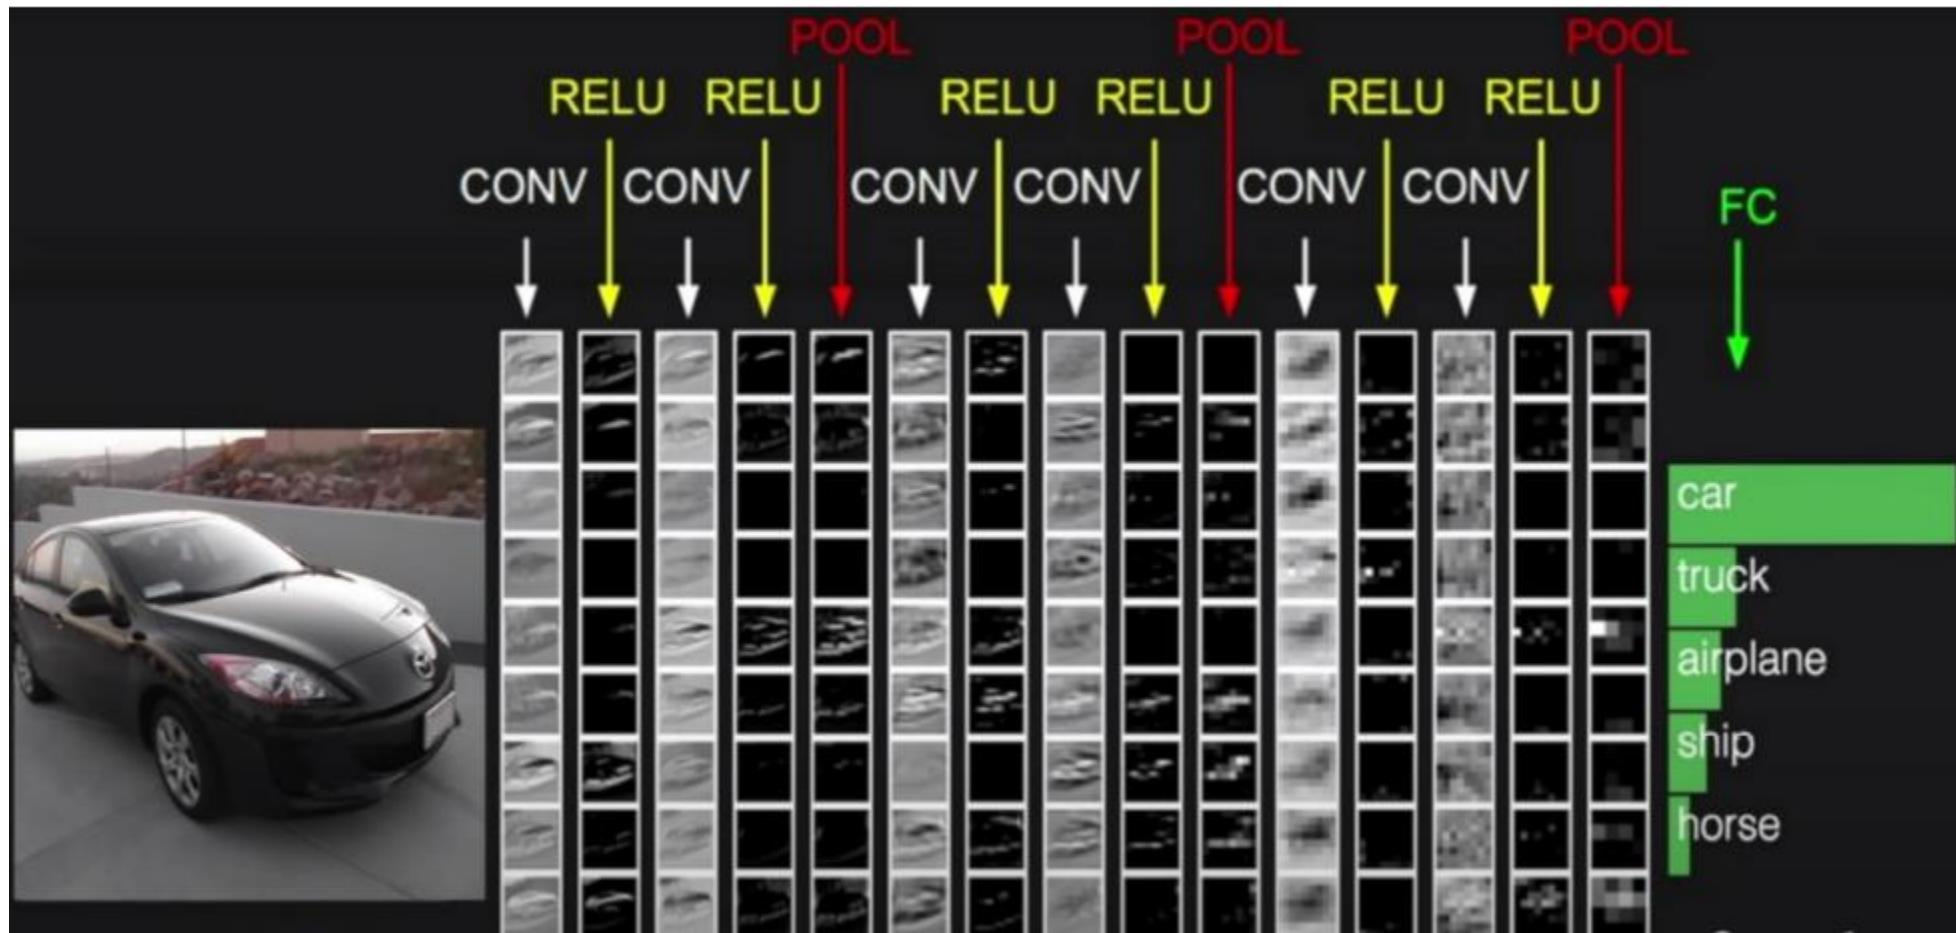
- Convolutional layer
- Pooling layer
- Fully connected layer
- Activation function



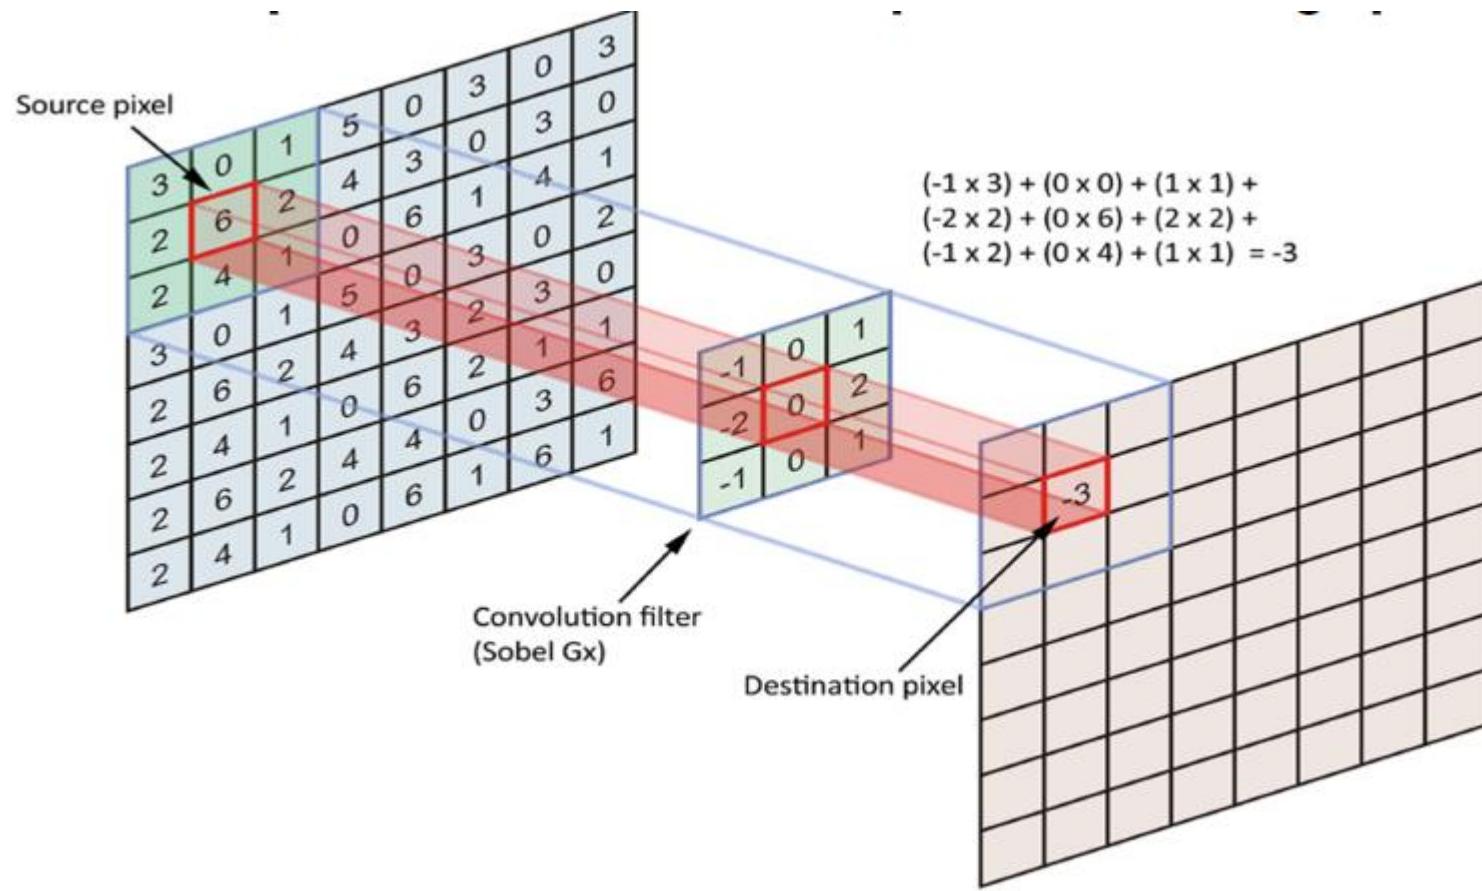
# مقدمه‌ای بر CNN



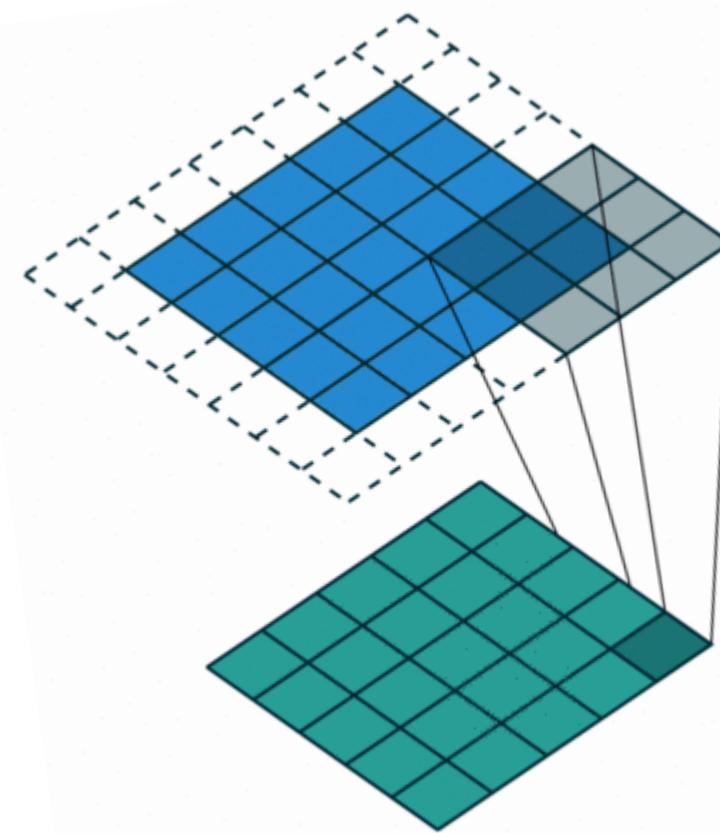
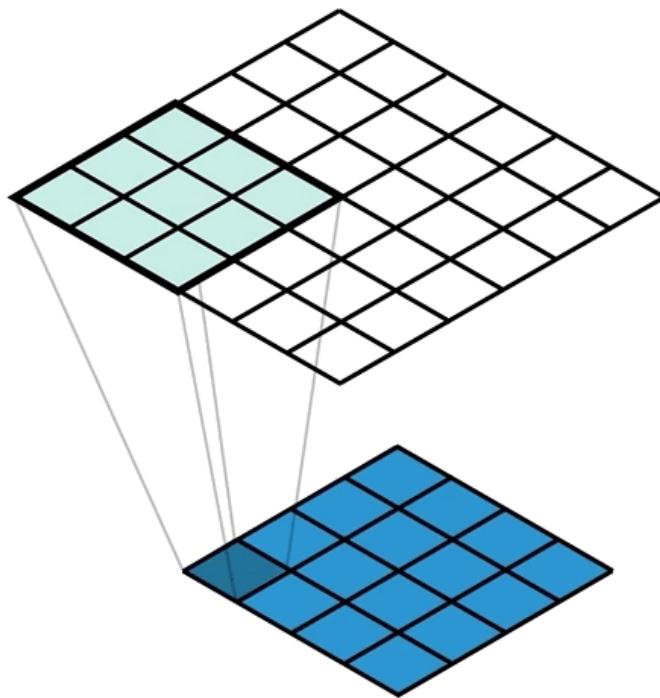
# مقدمه ای بر CNN



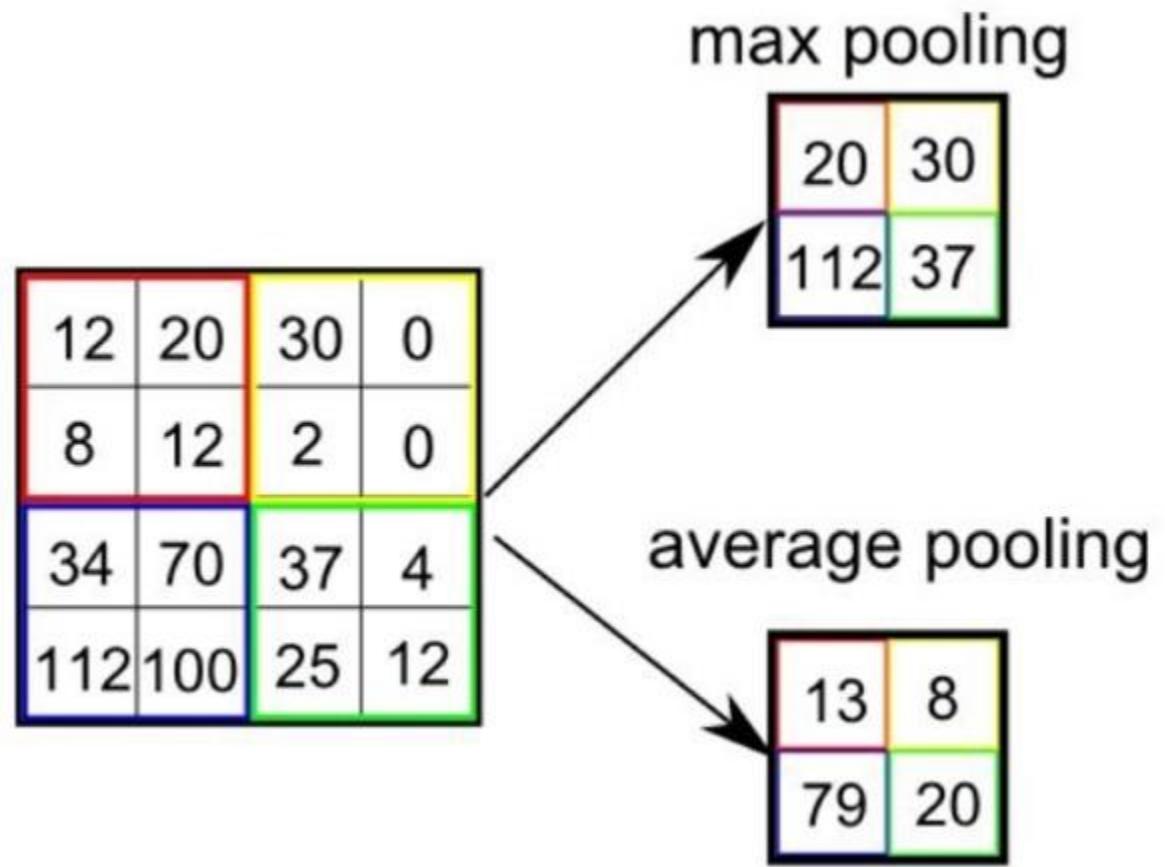
# مقدمه ای بر CNN



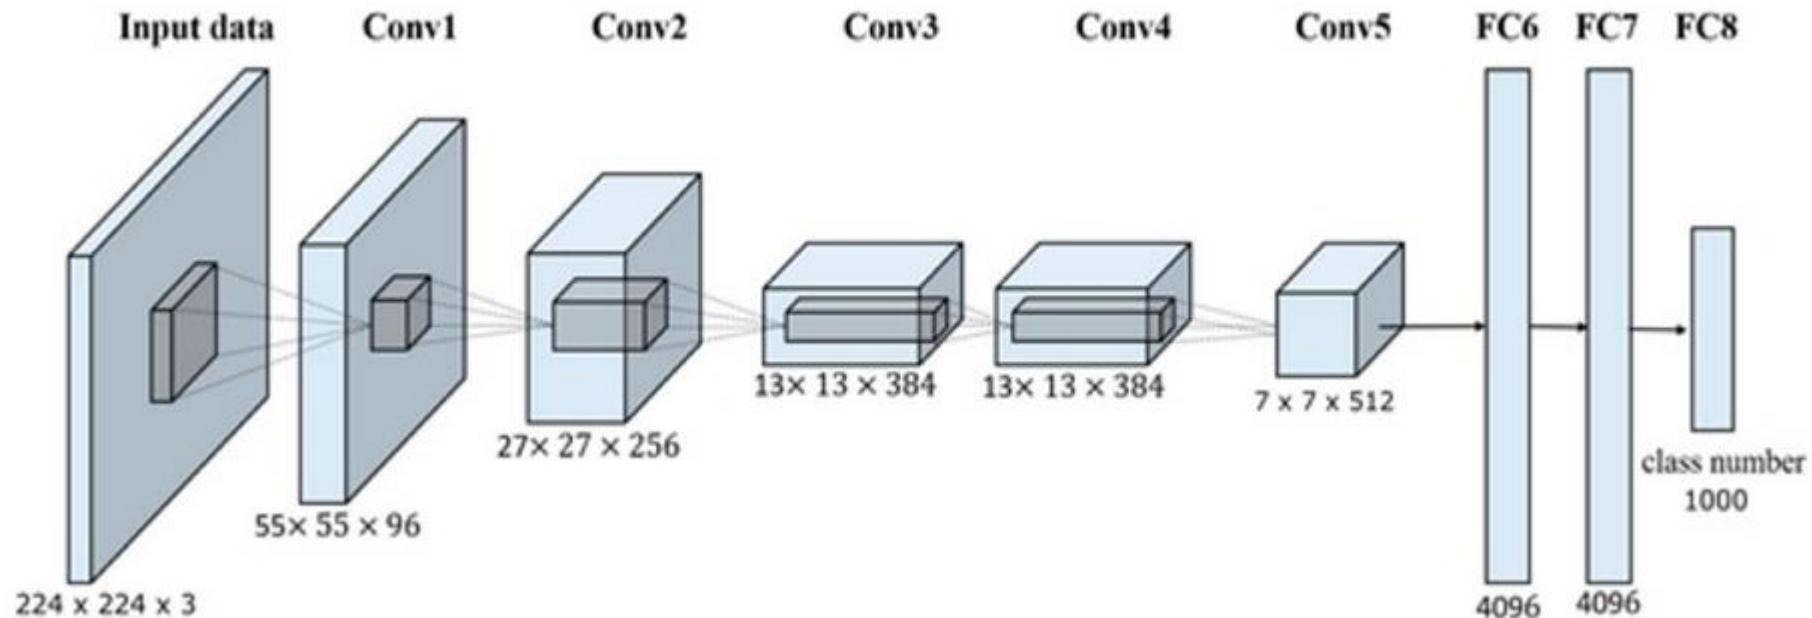
# مقدمه‌ای بر CNN



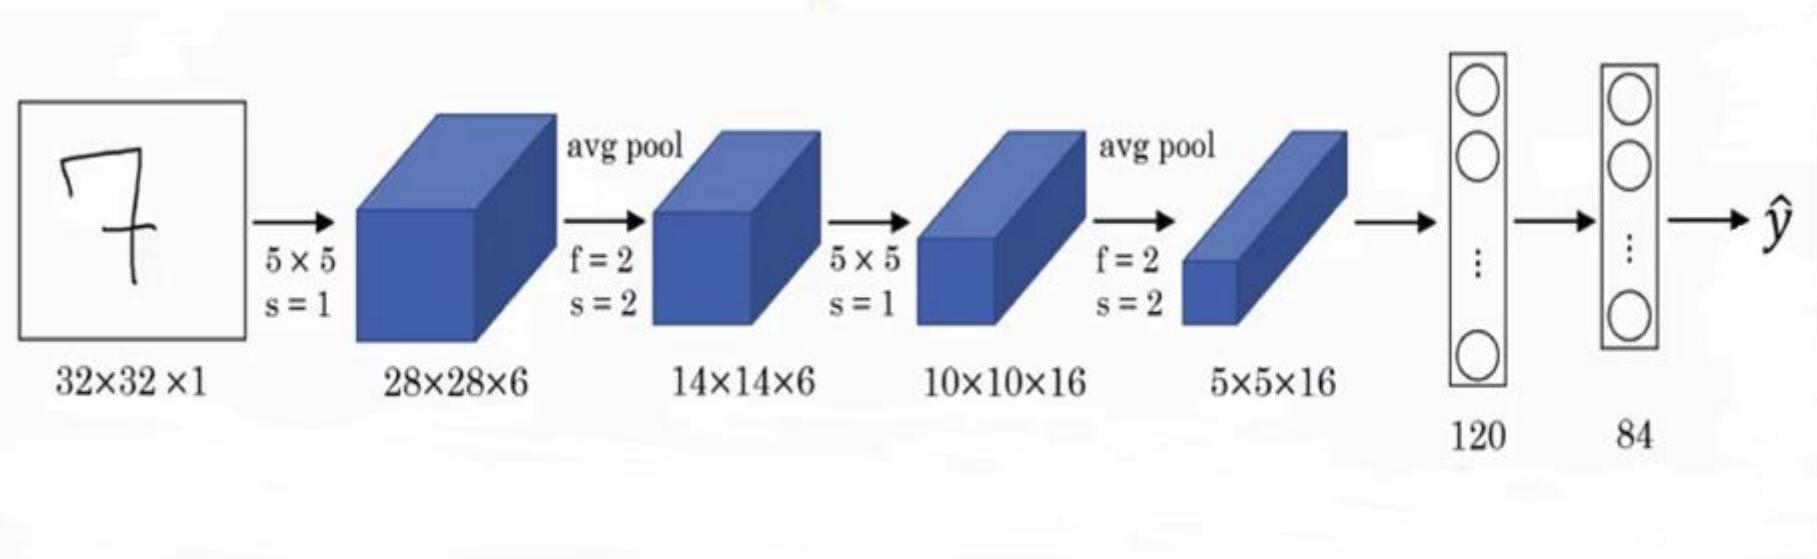
# مقدمه‌ای بر CNN



# مقدمه‌ای بر CNN

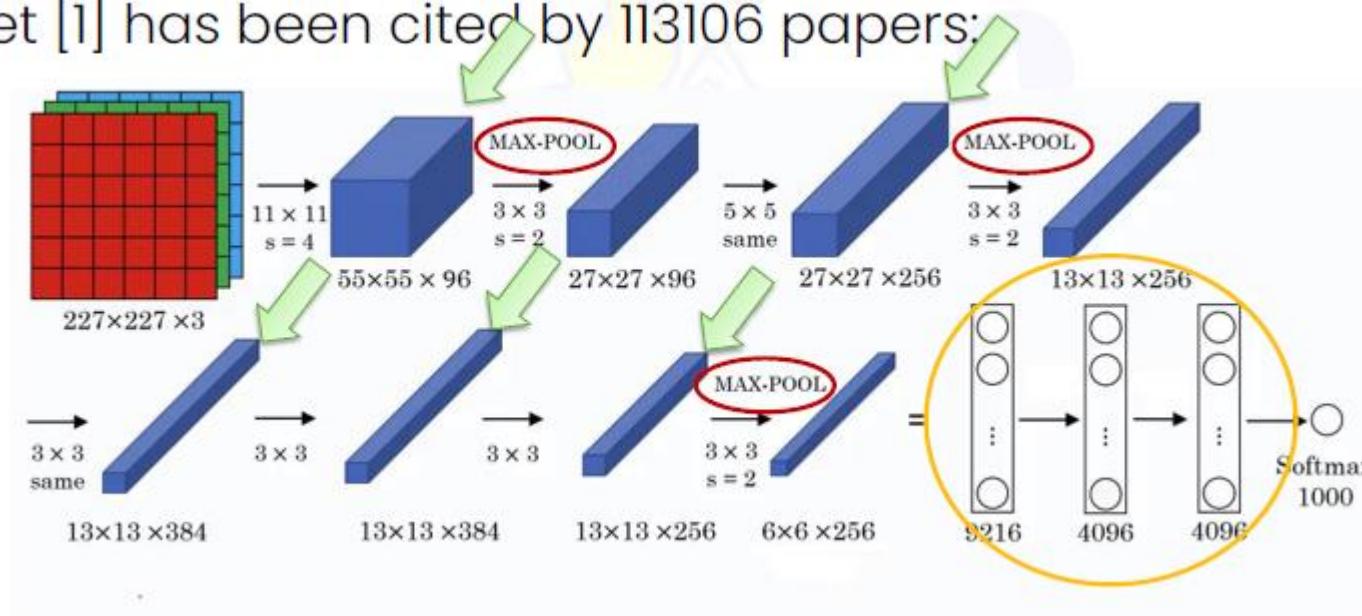


# ساختار LeNet



# ساختار AlexNet

Alex-Net [1] has been cited by 113106 papers:



این شبکه حدود ۲۰ میلیون پارامتر دارد

Alex Innovation ▪

▪ معرفی Relu

▪ Multiple GPU

▪ Dropout

▪ Data augmentation

▪ مشکل اصلی

▪ ساختار مشخصی نداشت

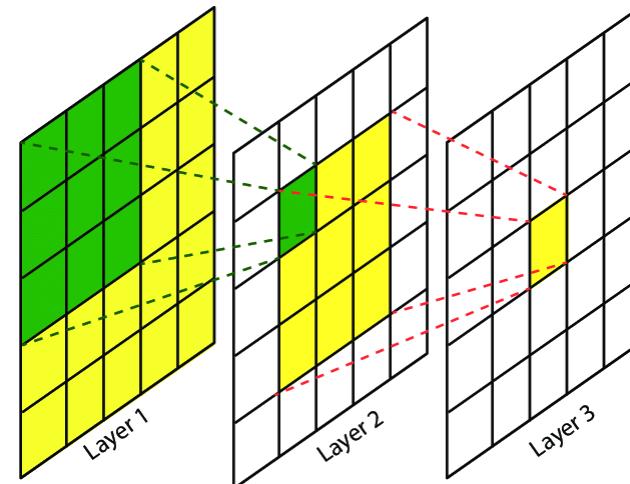
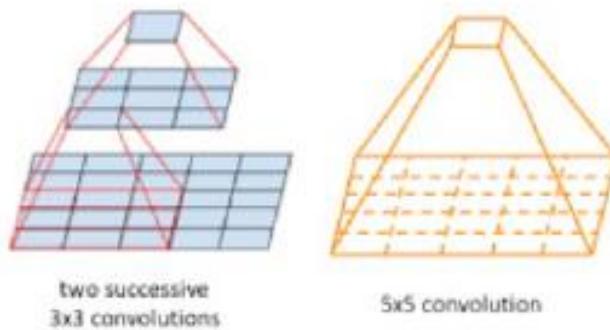
▪ Trial and error

# VGG Family

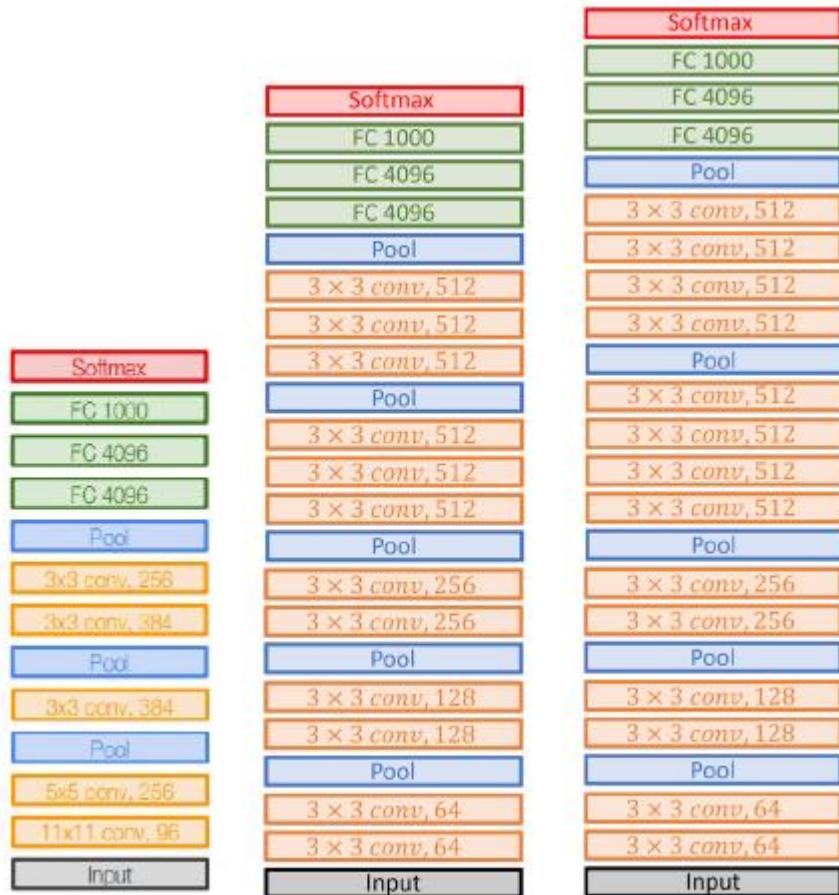
## VGG

### VGG19 و VGG16

- یکی از بهبودهای VGG نسبت به AlexNet عمیق تر بودن شبکه است این شبکه چندین لایه کانولوشن (با هسته  $3 \times 3$ ) متوالی را با لایه های کانولوشن با هسته های بزرگتر AlexNet جایگزین نمود و در حقیقت به دلیل عمیق تر بودن شبکه، پروسه استخراج ویژگی بهبود می یابد ساختار شبکه VGG ساده است کل شبکه از هسته های با سایز یکسان و max pooling استفاده می کند



# VGG Family



AlexNet

VGG16

VGG19

Cov  $3 \times 3$ , stride 1, padding 1 ▪

Max pool  $2 \times 2$ , stride 1 ▪

Stage 1: conv-conv-pool

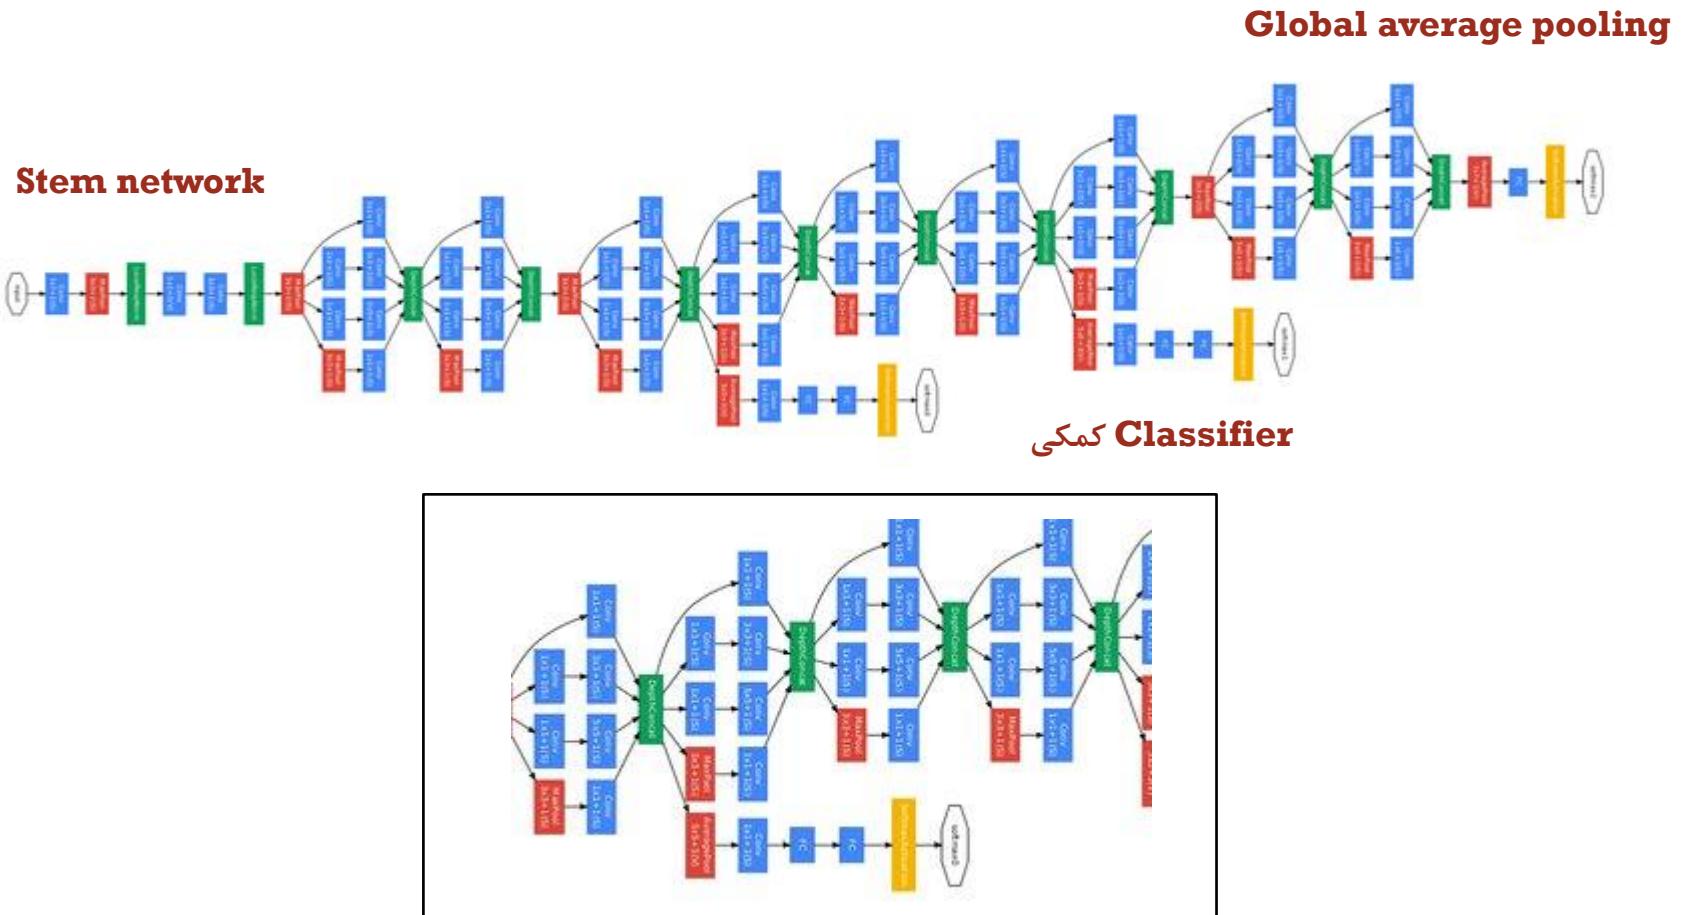
Stage 2: conv-conv-pool

Stage 3: conv-conv-pool

Stage 4: conv-conv-conv-[conv]-pool

Stage 5: conv-conv-conv-[conv]-pool

# GoogLeNet

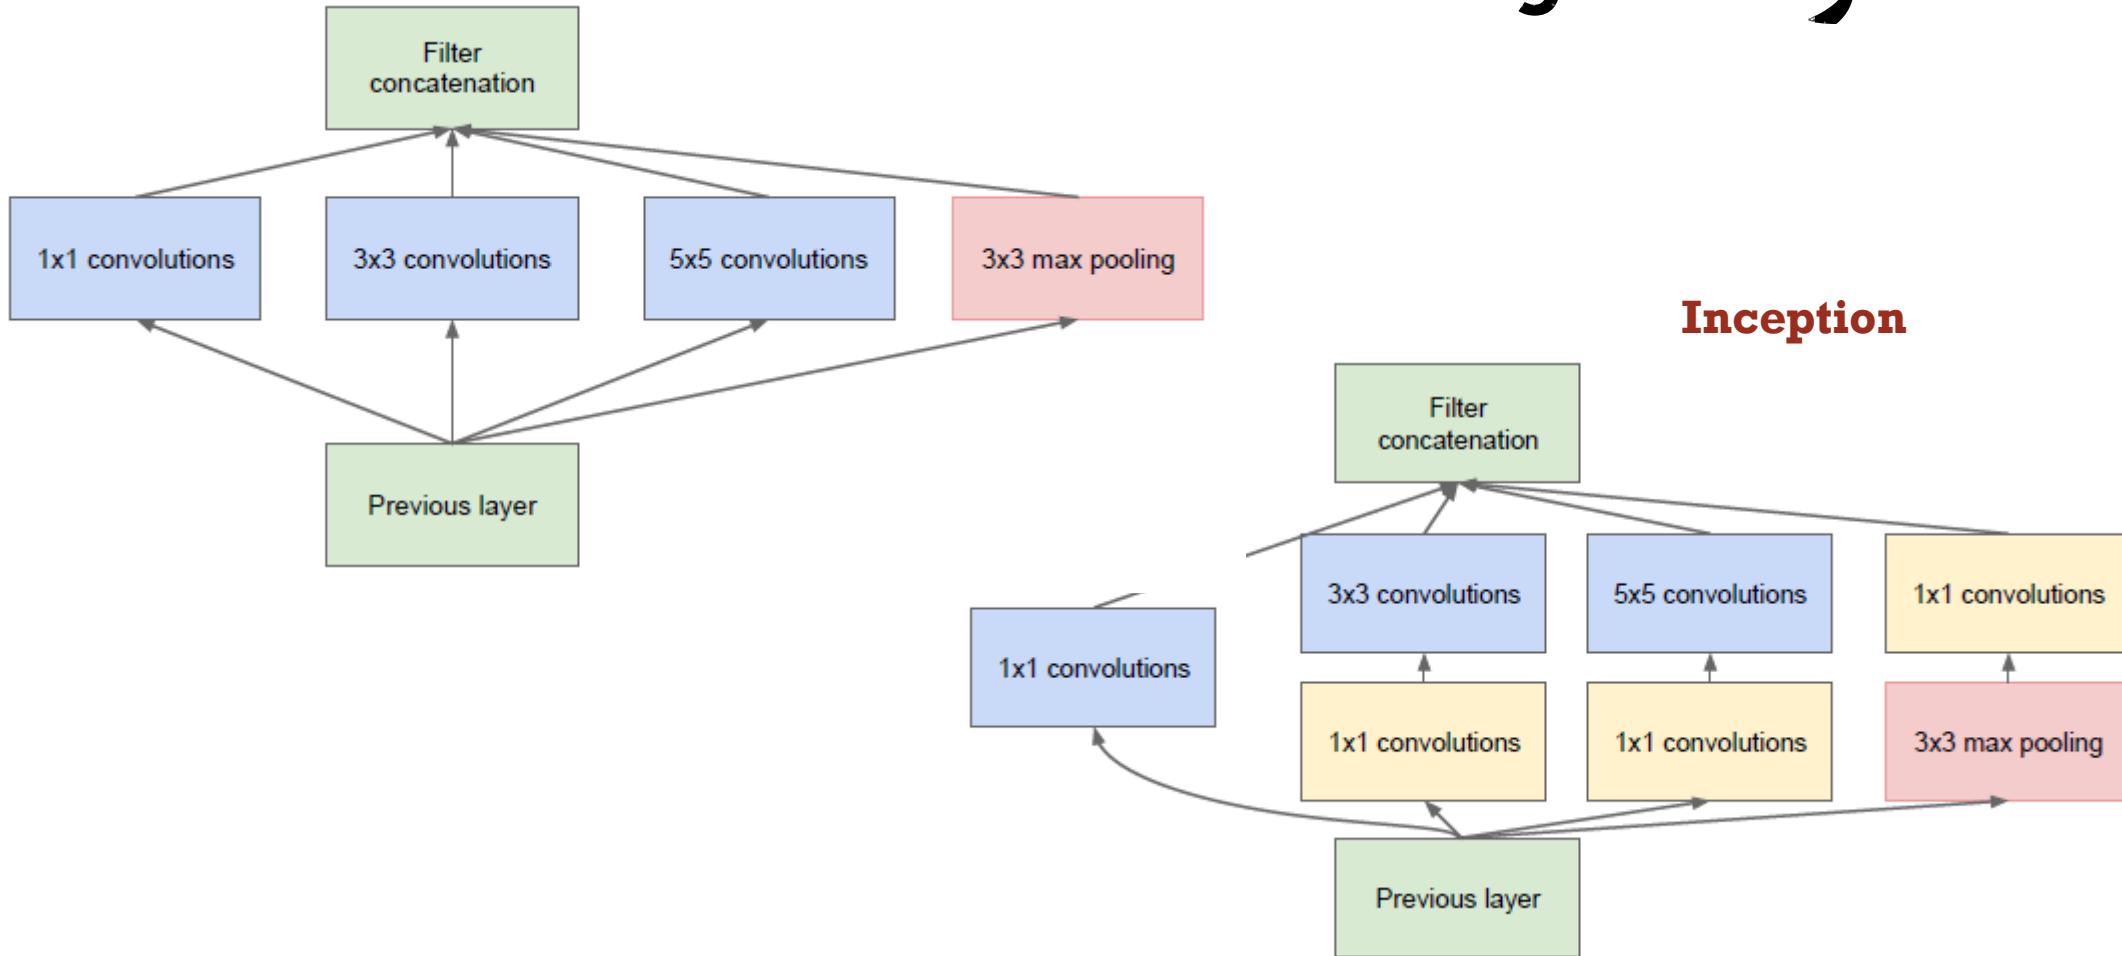


## GoogLeNet

- ساختار شبکه را به مازول هایی تقسیم می کند یک ساختار Inception برای افزایش عمق و عرض شبکه با کاهش پارامترهای شبکه پیشنهاد می دهد.

- کانولوشنی با هسته های متفاوت استفاده می کند عمق کل شبکه به ۲۲ لایه می رسد

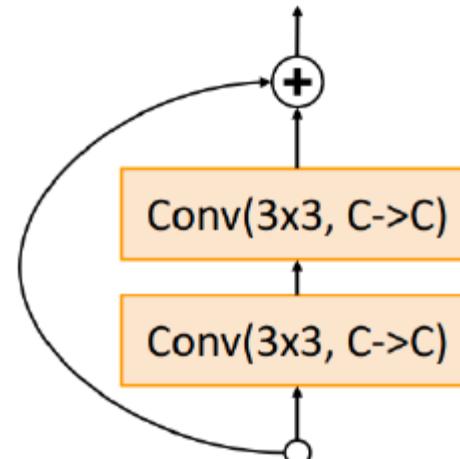
# ساختار GoogleNet



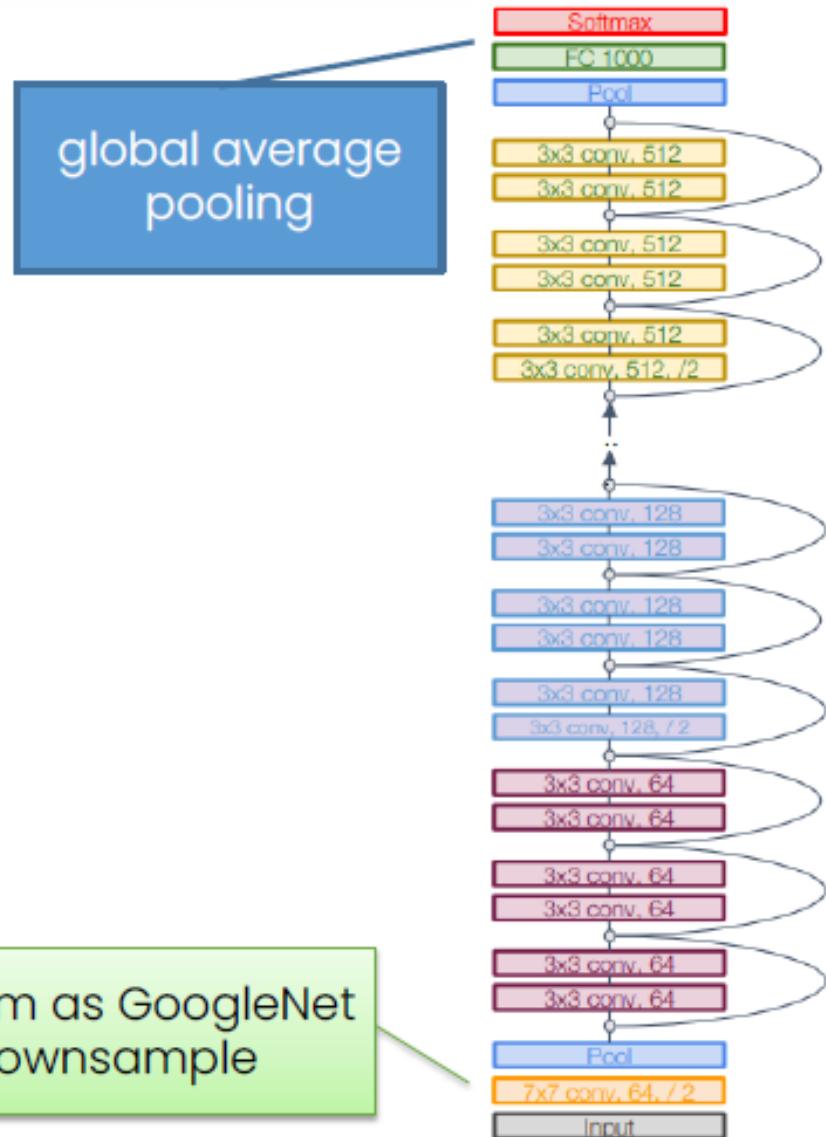
# ساختار ResNet

## ResNet ▪

- هر مازول آن از تعدادی لایه متوالی و یک shortcut تشکیل می شود این shortcut ورودی و خروجی مازول را به هم متصل می کند



"Basic"  
Residual block

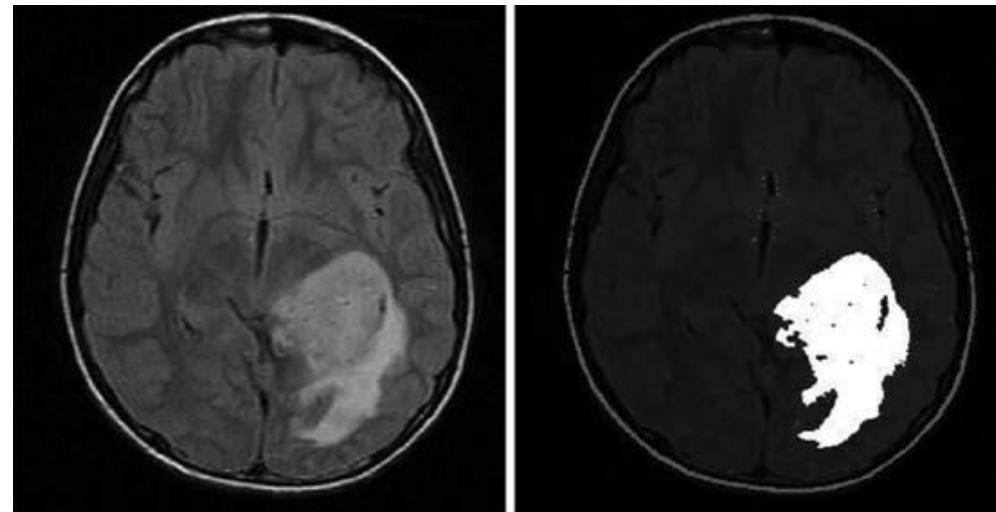


Uses stem as GoogleNet  
to downsample

# قطعه بندی تصاویر پزشکی

## Image segmentation ▪

▪ یک تصویر را به چندین ناحیه تقسیم می کند که خصوصیات مشابهی دارند و می توانند برای جداسازی یک target از پس زمینه بکار گرفته شود در حال حاضر، روش‌های قطعه بندی سریع و دقیقی توسعه داده شده اند اما هدف کلی این است که با ترکیب تئوری‌ها و روش‌های جدید، الگوریتمی بیابیم که بتواند به طیف وسیعی از تصاویر اعمال شود (CT، MRI، PET و X-ray UI)

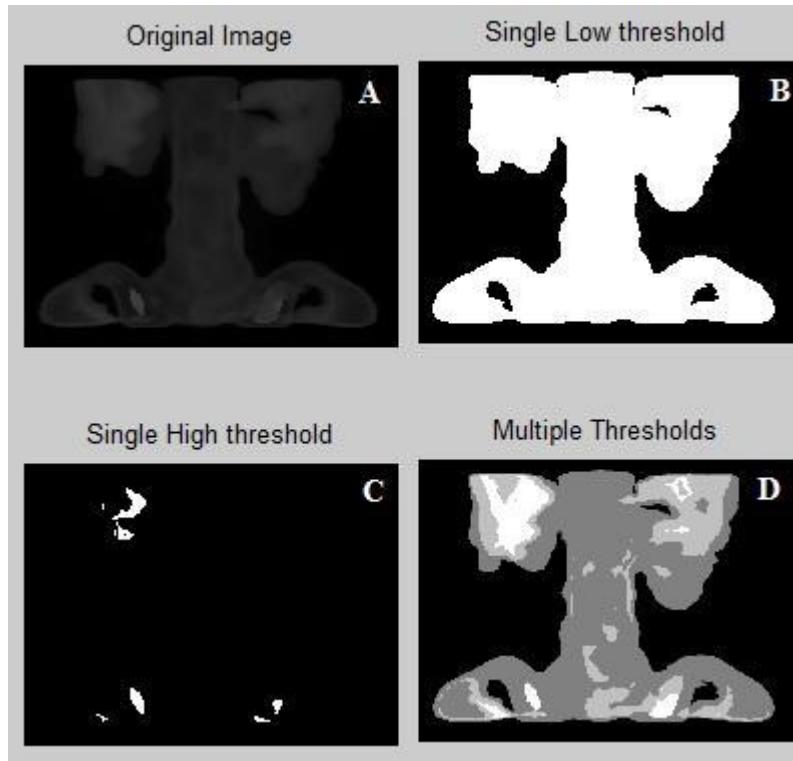


# قطعه بندی تصاویر پزشکی

- با وجود اینکه الگوریتم های قطعه بندی در سال های اخیر توسعه زیادی یافته اند اما هنوز یک الگوریتم جامع که برای طیف وسیعی از تصاویر پاسخگو باشد معرفی نشده است
- روش های کلاسیک: ساده و سریع هستند اما دقیق قطعه بندی نمی توانند گارانتی شود
  - Threshold-based segmentation
  - Region-based segmentation
  - Edge detection-based segmentation
- روش های مبتنی بر یادگیری عمیق: در مقایسه با روش های کلاسیک، روش های مبتنی بر یادگیری عمیق نتایج فوق العاده ای بدست آورده اند
  - U-Net
  - Fully Convolutional Neural Networks

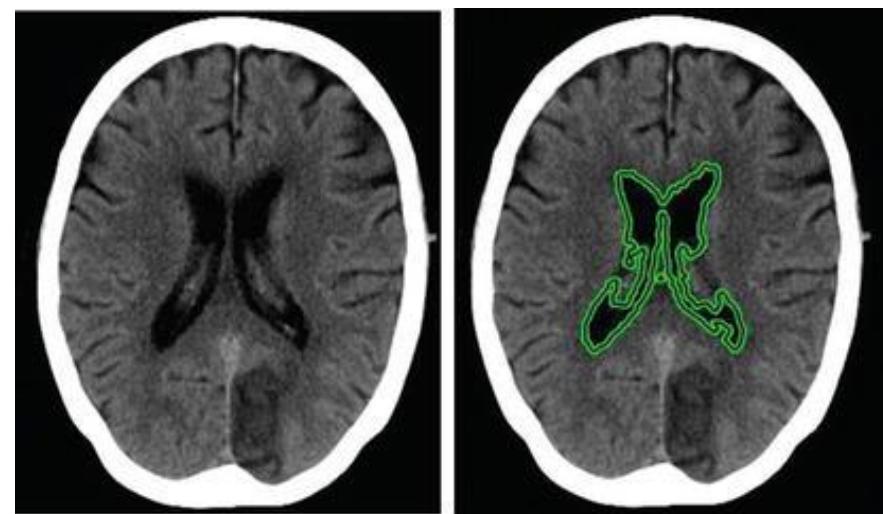
# قطعه بندی مبتنی بر حد آستانه

Threshold-based segmentation ▪



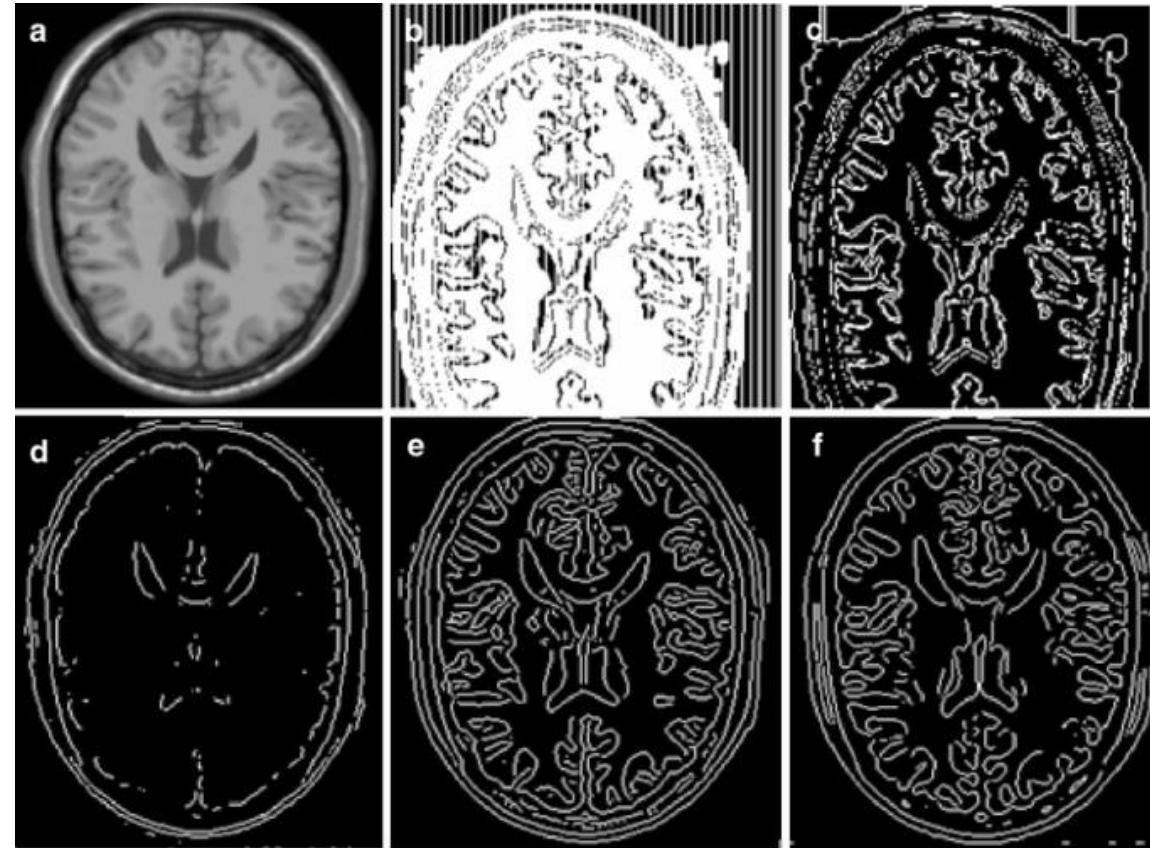
# قطعه بندی مبتنی بر ناحیه

Region-based segmentation ▪



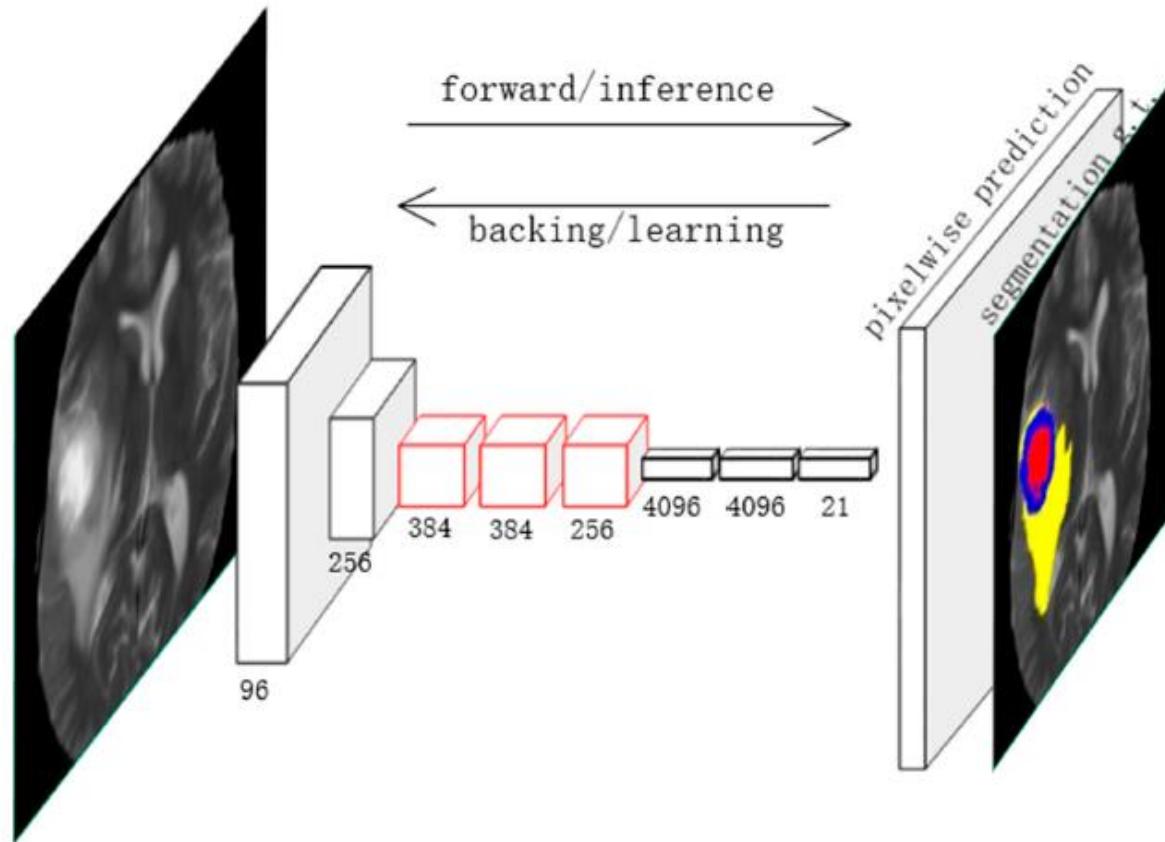
# قطعه بندی مبتنی بر لبه

Edge detection-based segmentation ▪

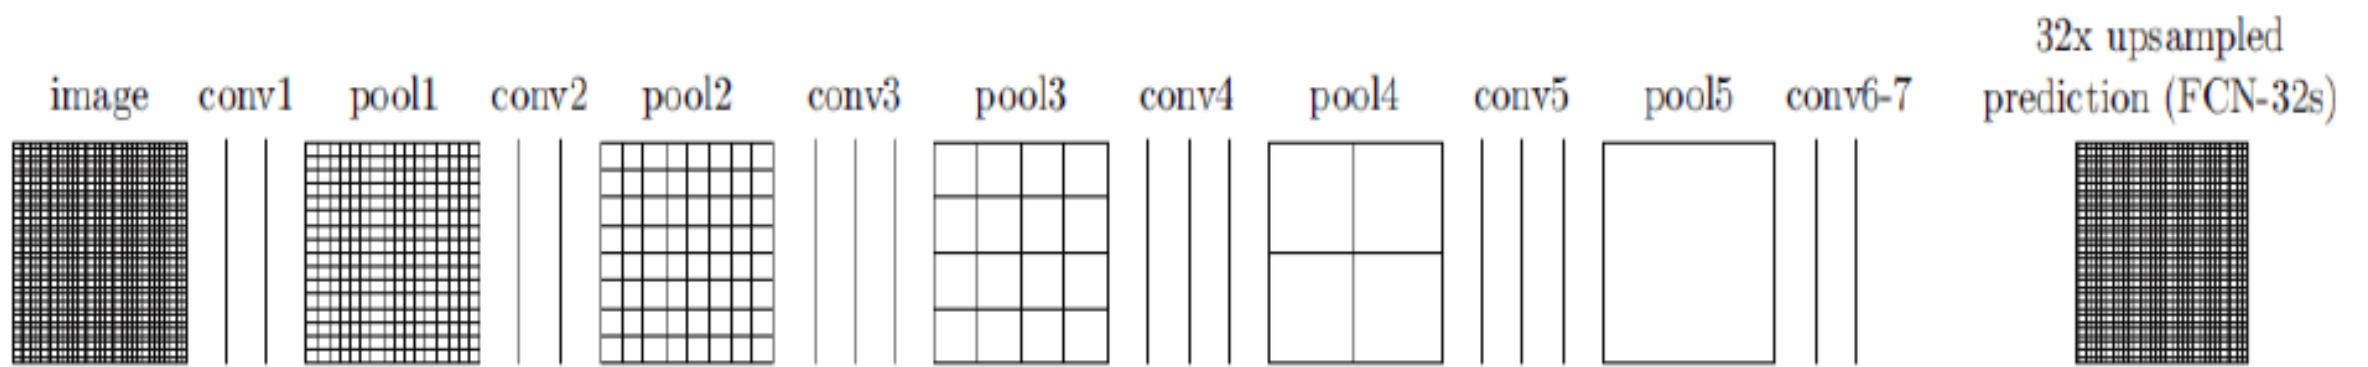


# شبکه FCN

Fully convolutional neural network ▪



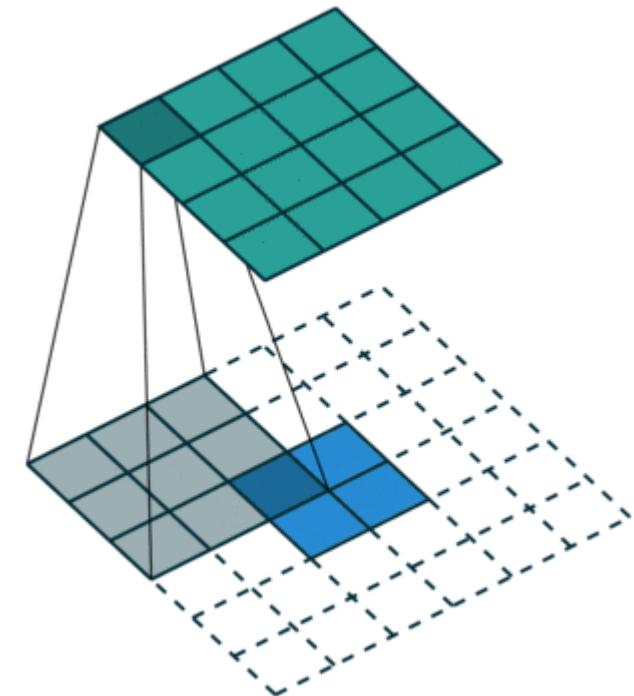
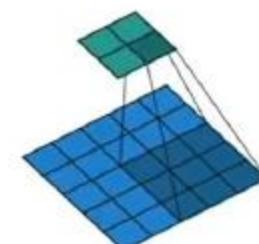
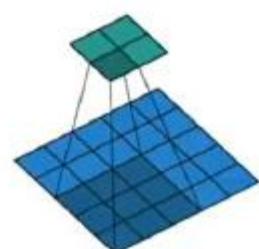
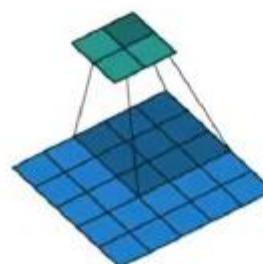
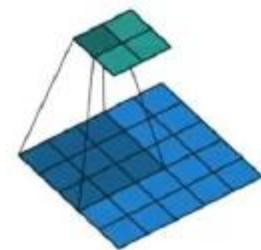
# شبکه FCN



# شبکه FCN

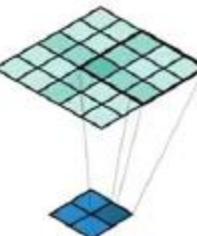
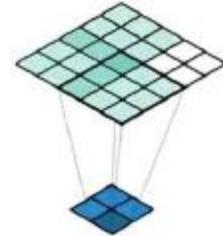
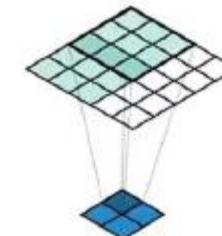
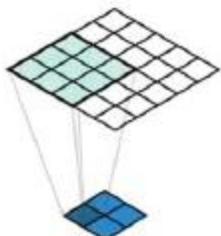
Regular Convolution (stride=2)

output

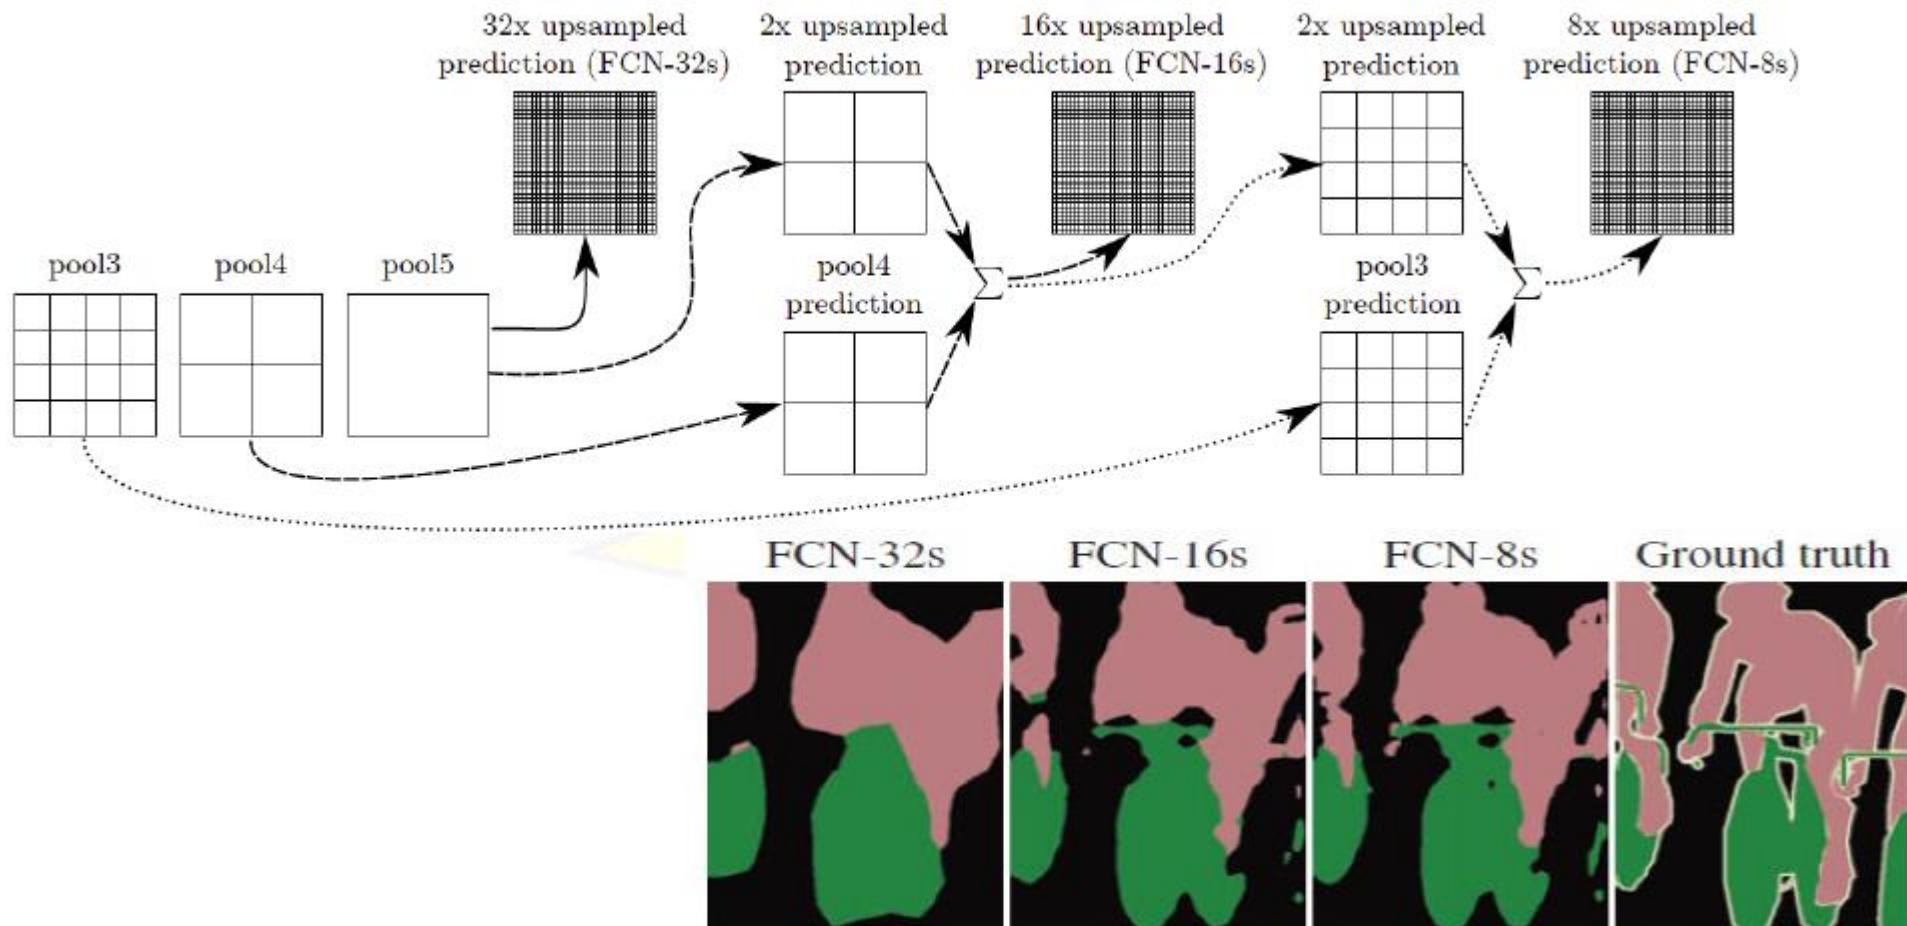


Transposed Convolution (stride=2)

output



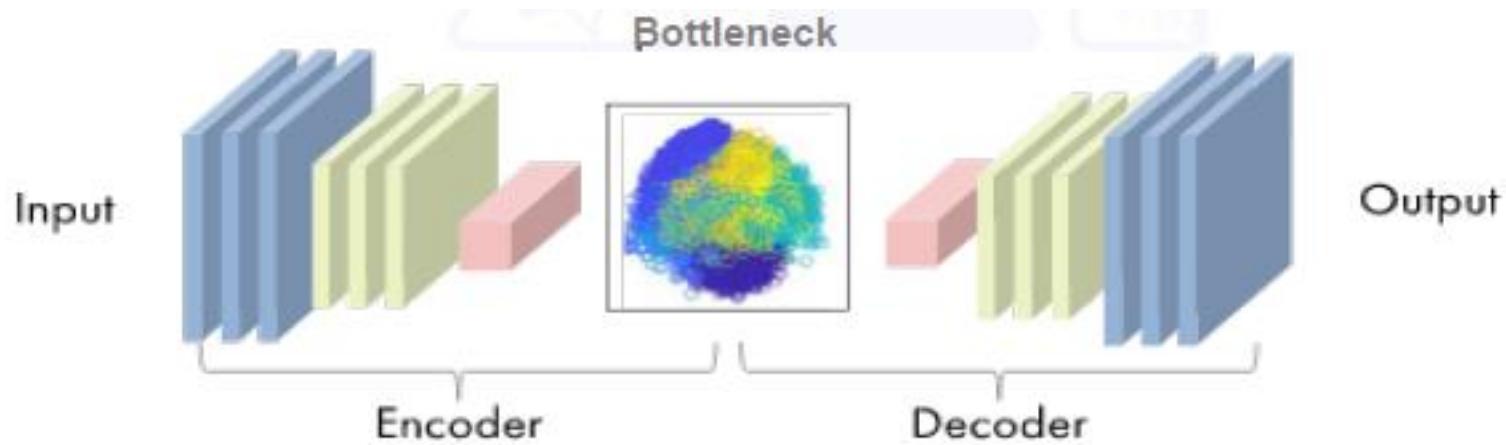
# شبکه FCN



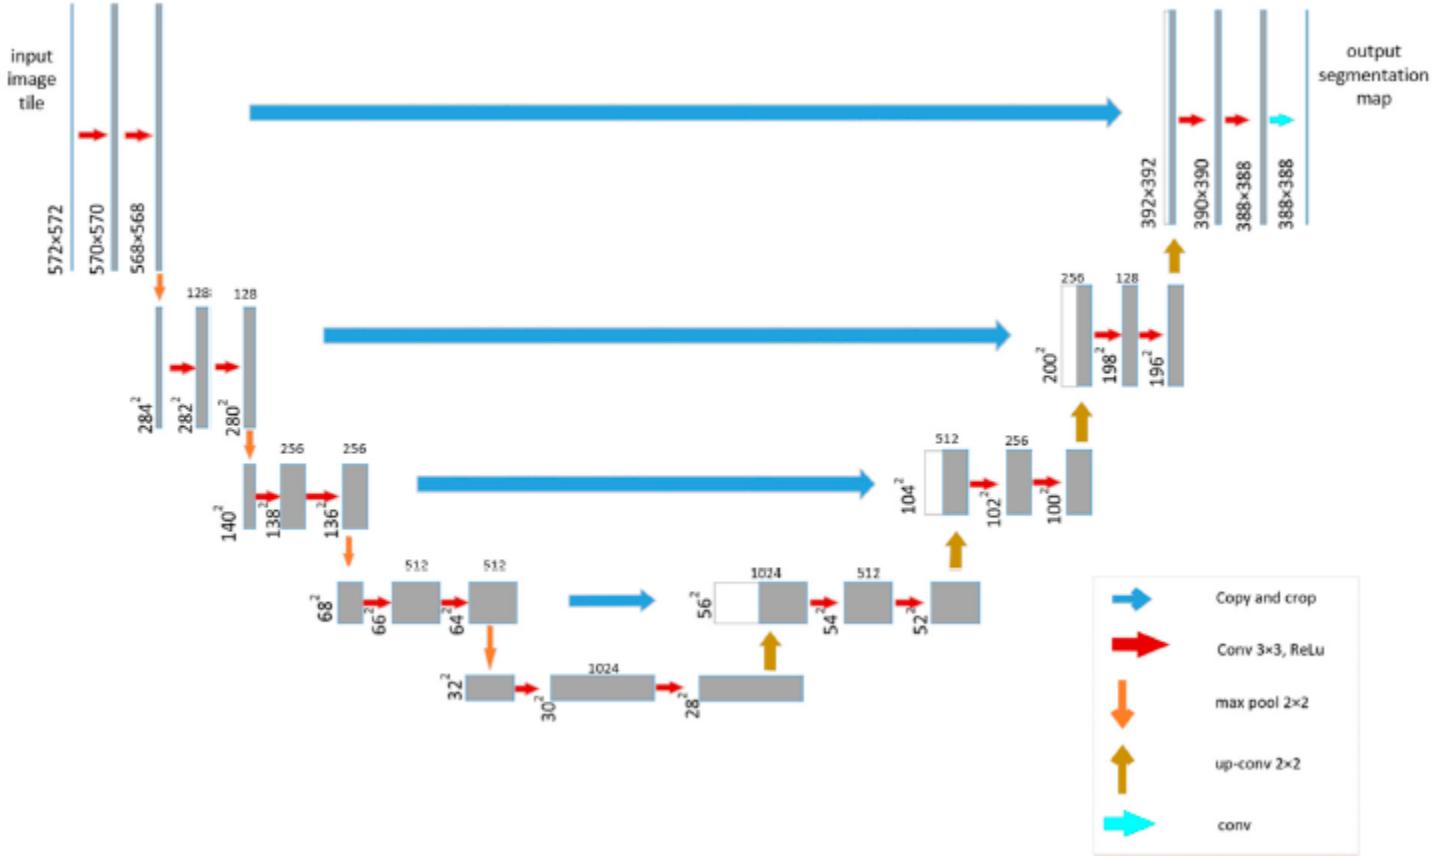
# شبکه U-Net

شبکه U-Net از U کانال و skip connection تشکیل شده است

- Encoder
- Bottleneck
- Decoder



# شبکه U-Net



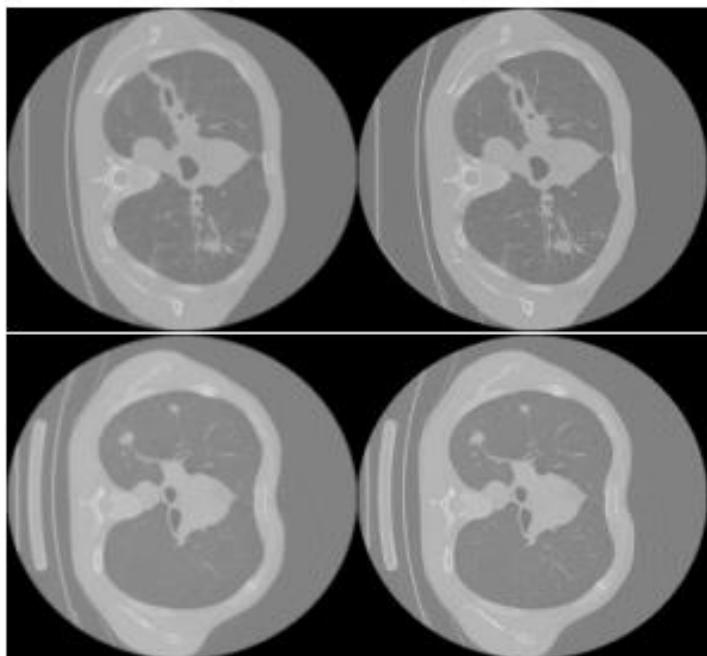
# افزایش تصاویر پزشکی

## Image augmentation ▪

- مدل‌های generative به عنوان دسته‌ای از مدل‌های آماری در نظر گرفته می‌شوند که می‌توانند نمونه‌های جدید داده را تولید کنند

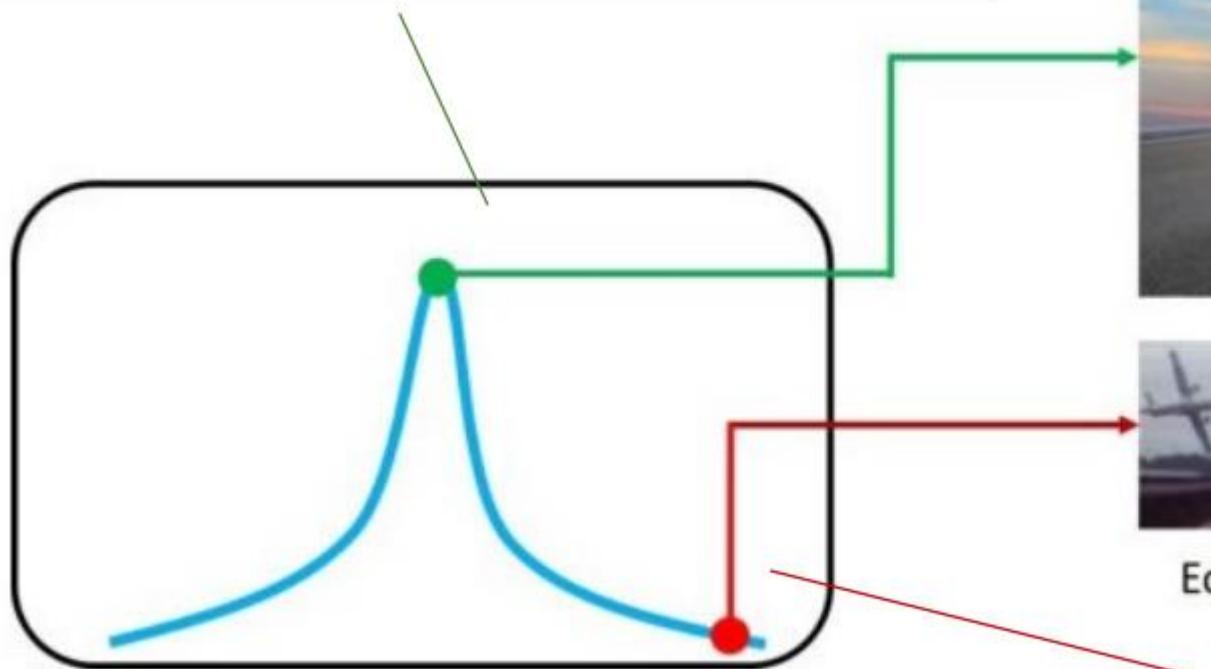
▪ برخی از شبکه‌های Generative شناخته شده  
Variational Encoder ▪

- Generative Adversarial Network (GAN) ▪
- Deep Convolutional GAN ▪
- Progressive GAN ▪



# Variational Autoencoder

Common weather condition



**95% of driving data**

1. Sunny 2. Highway 3. Straight road



Edge cases



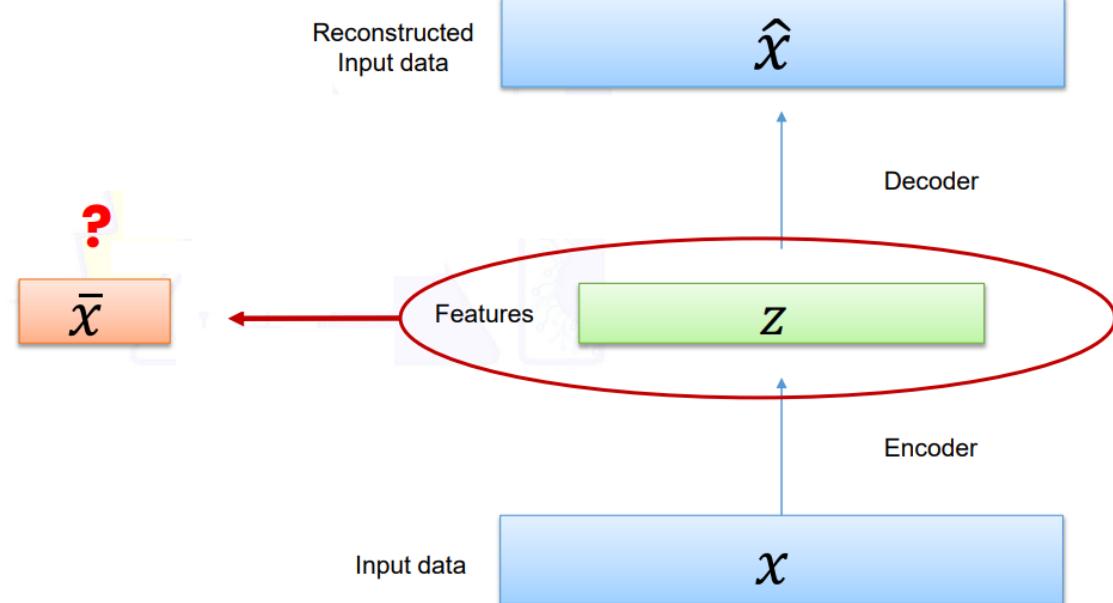
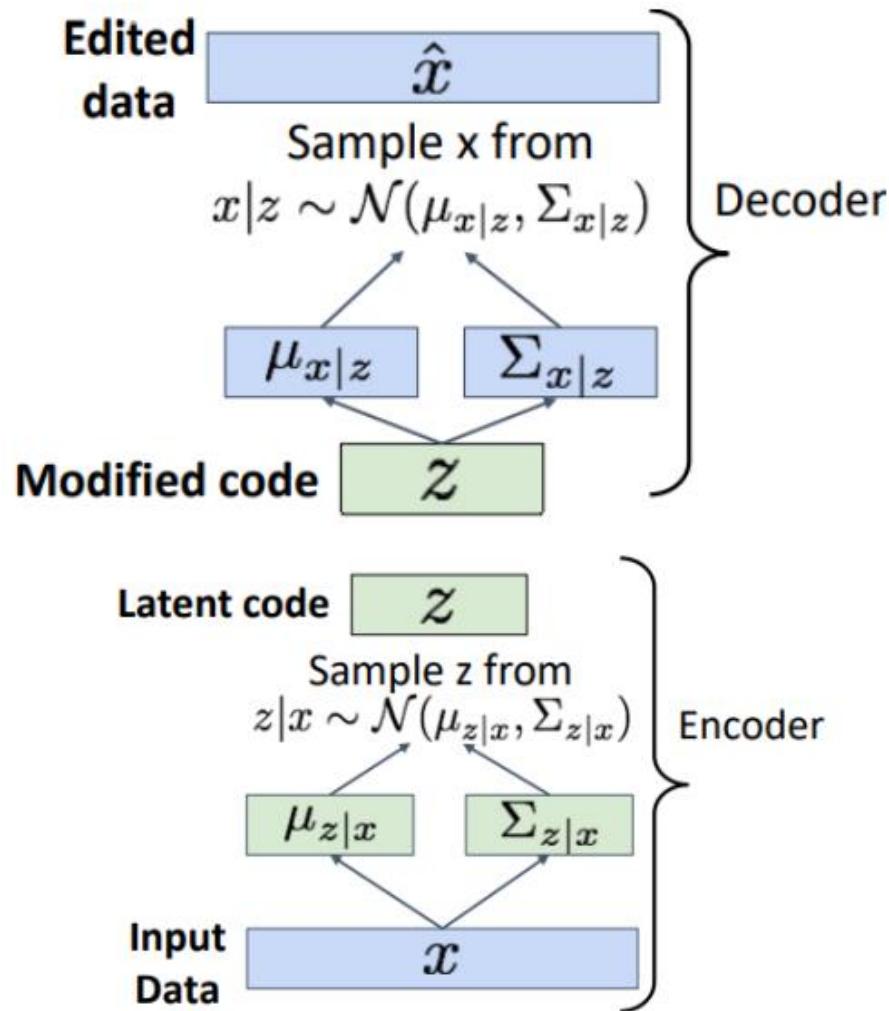
Rainy weather



Pedestrians

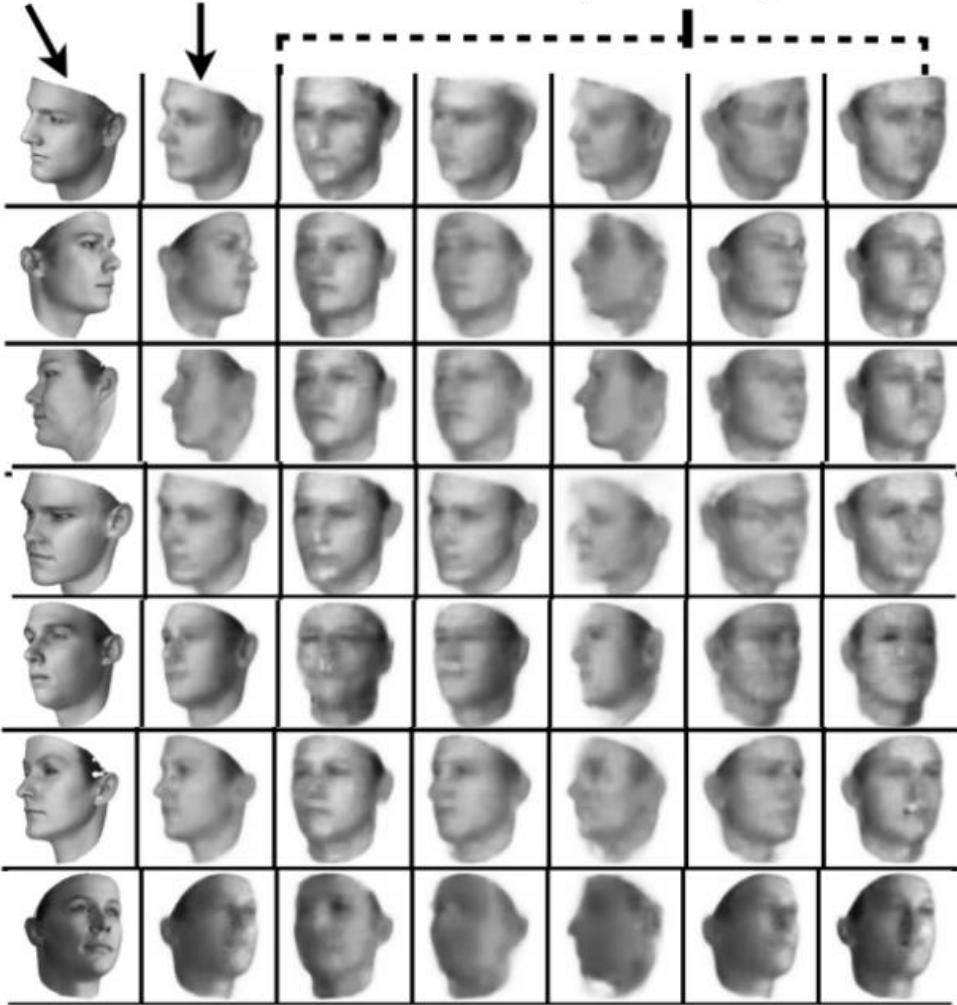
unlikely road weather condition

# Variational Autoencoder

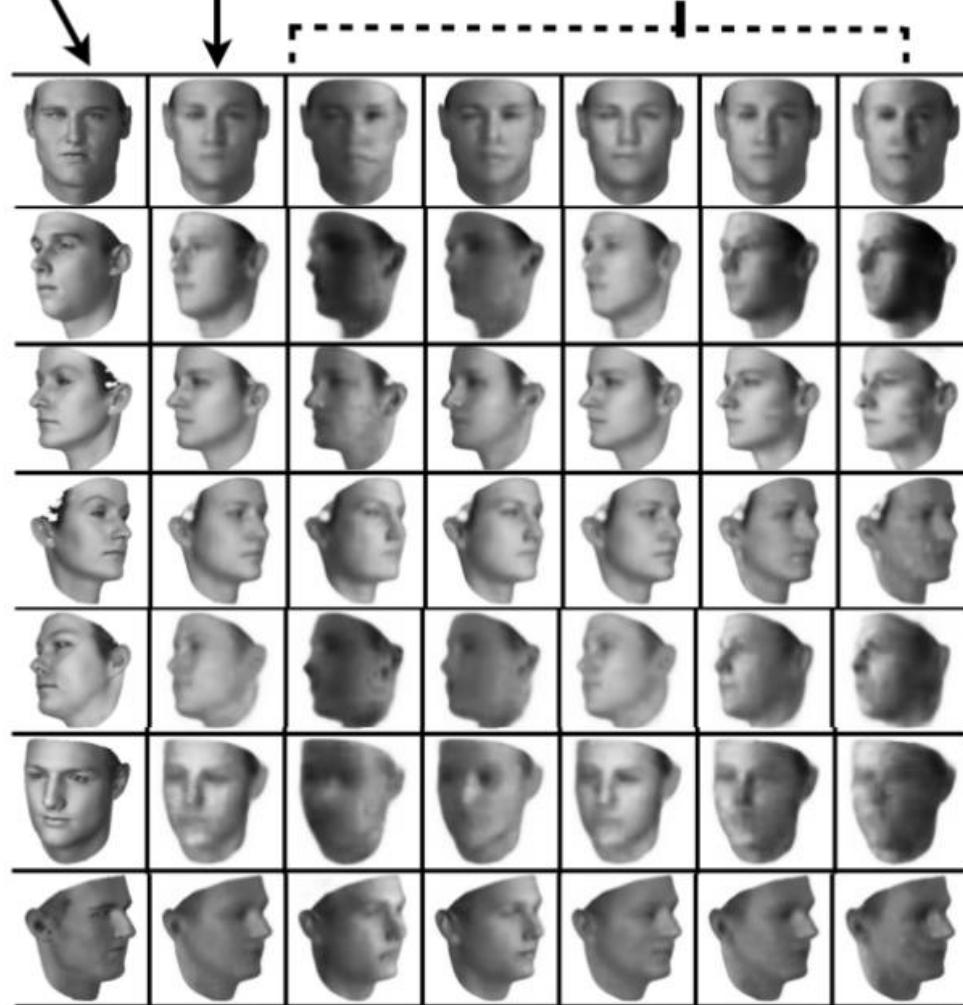


# Variational Autoencoder

Original   Reconstruction   Pose (Azimuth) varied

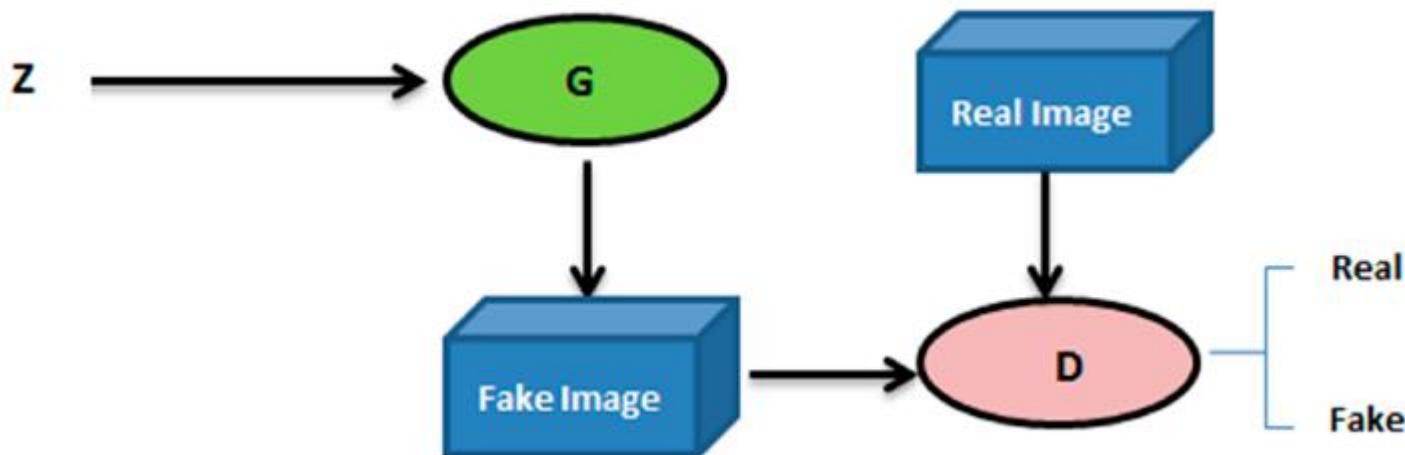


Original   Reconstruction   Light direction varied

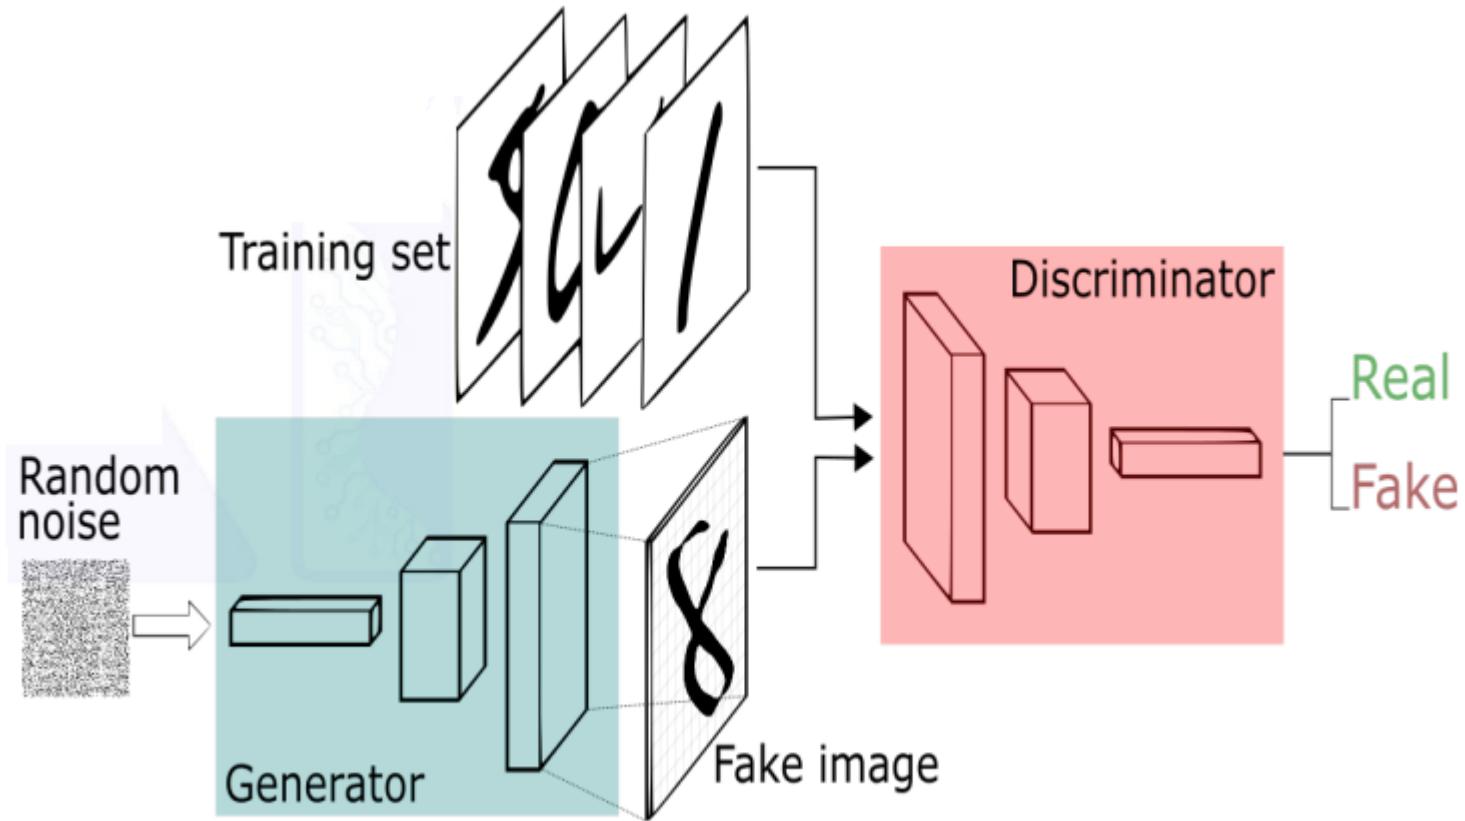


# شبکه GAN

- شبکه GAN شامل دو بخش می باشد
- بخش اول شبکه generation را نشان می دهد که نویز تصادفی  $z$  را دریافت می کند و یک تصویر جدید ایجاد می کند
- بخش دوم در مقابل بخش اول قرار دارد و برای قضاؤت در مورد اینکه تصویر واقعی است یا خیر مورد استفاده قرار می گیرد
- در حقیقت در فاز آموزش، دو شبکه که با یکدیگر رقابت می کنند تولید خواهد شد شبکه generation داده جعلی تولید می کند و شبکه adversarial (fake) صحبت داده تولید شده در مرحله قبل را تعیین می کند

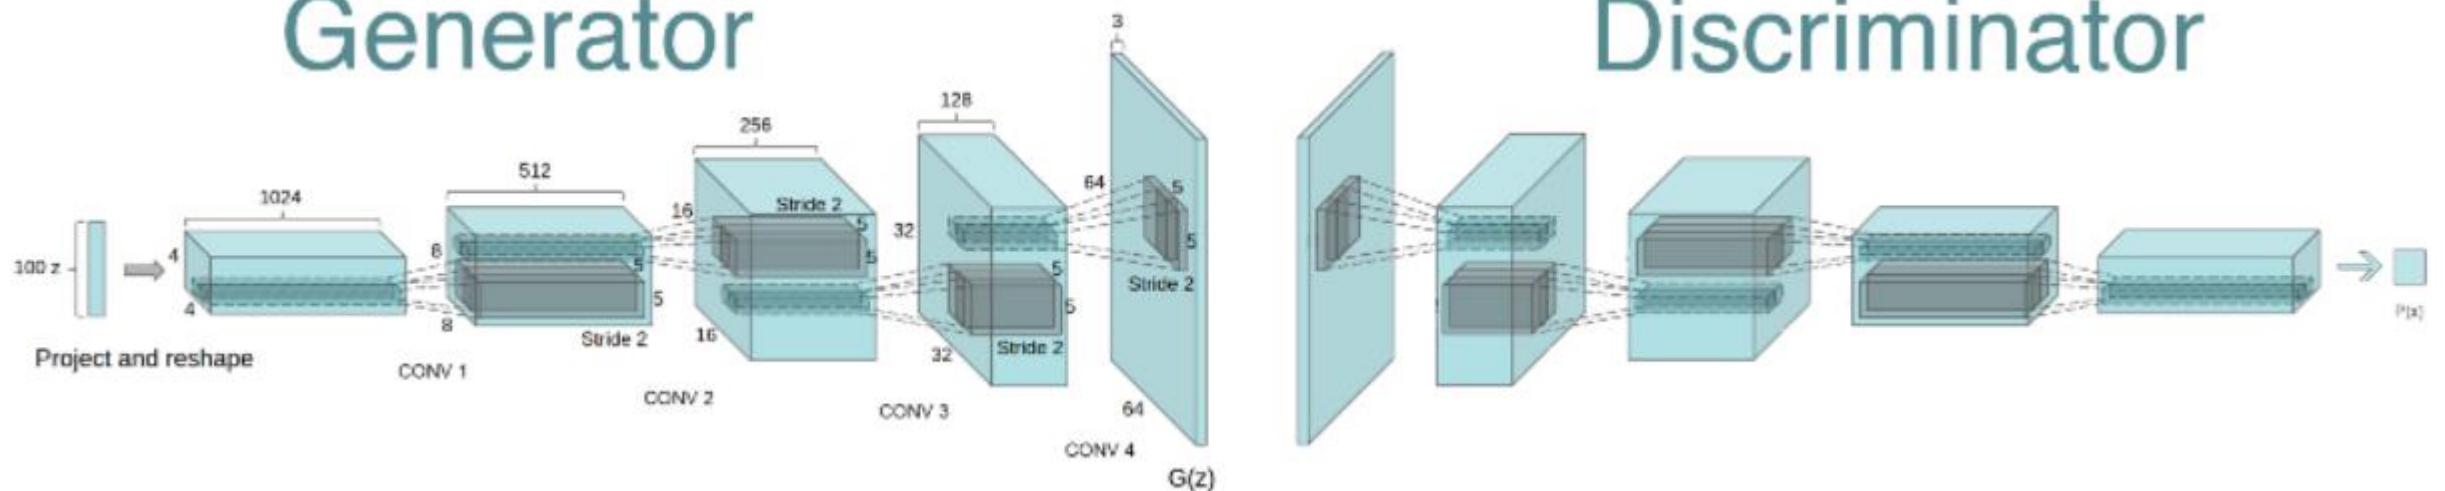


# GAN



# Deep Convolutional GAN

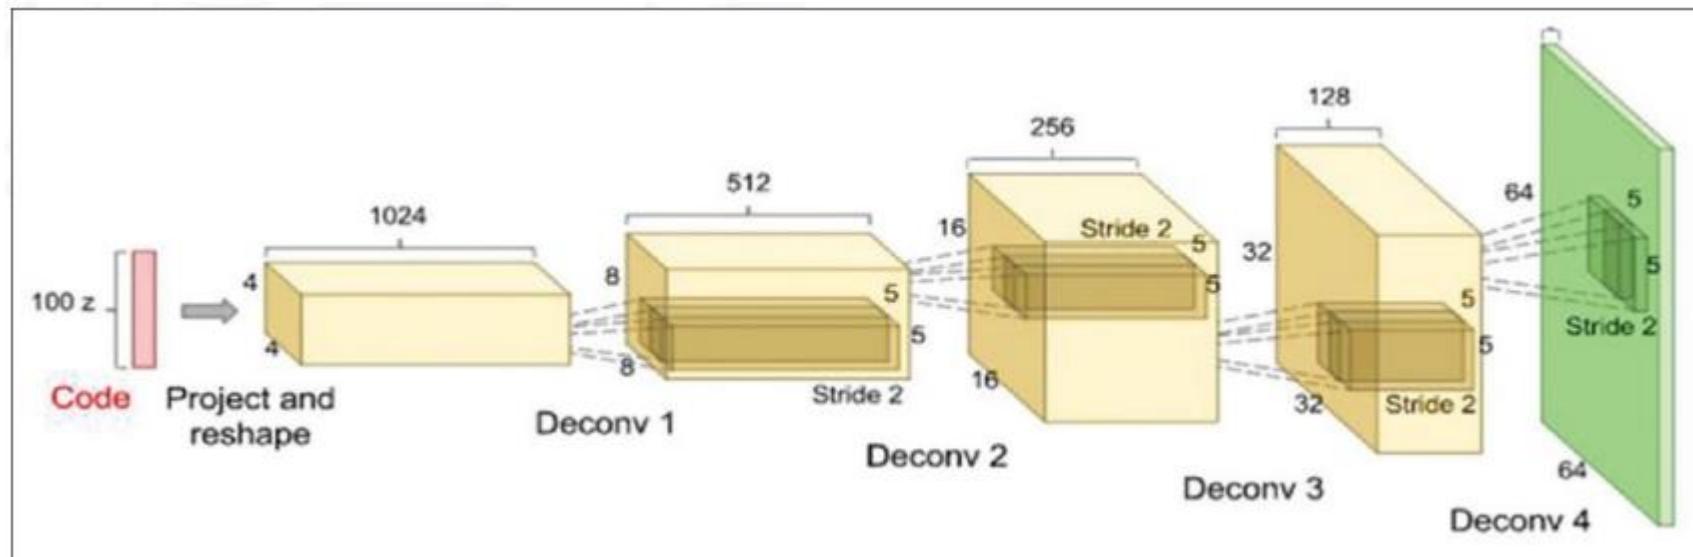
## Generator



## Discriminator

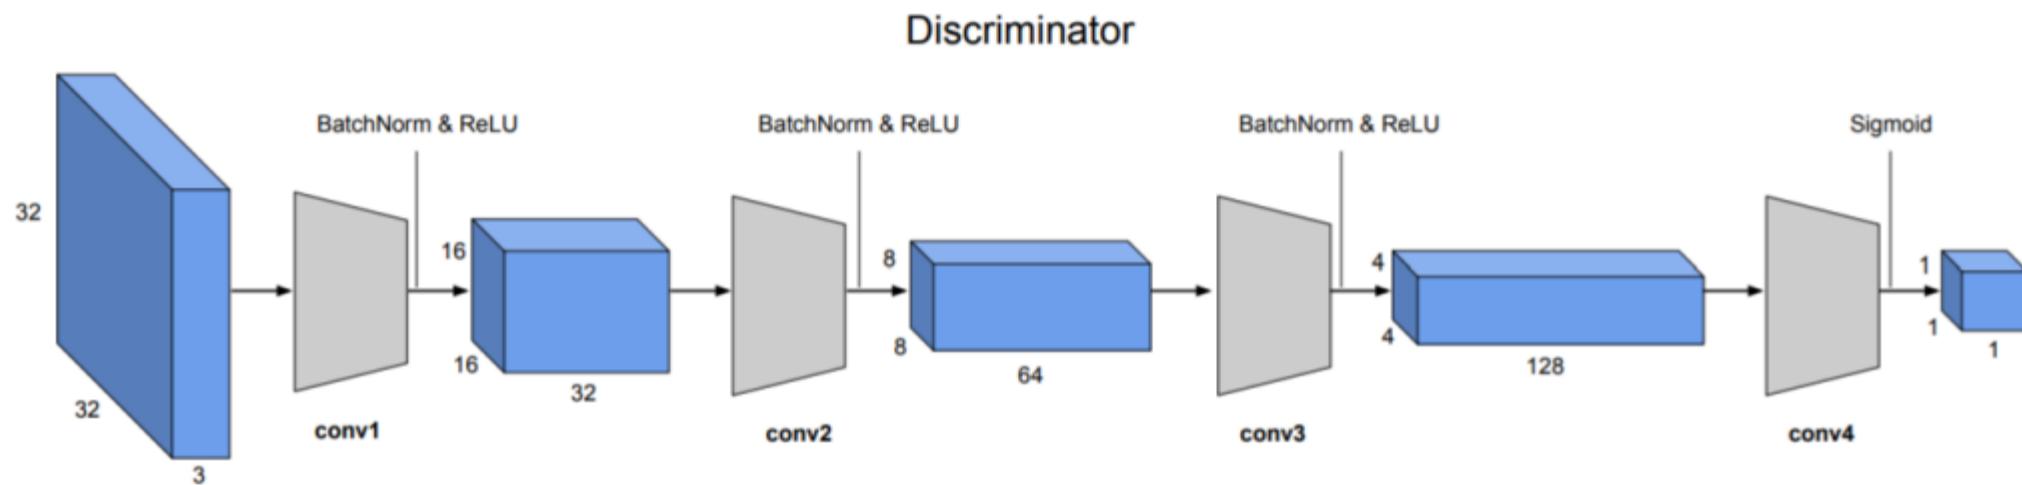
# Deep Convolutional GAN

▪ نمایی از شبکه Generator

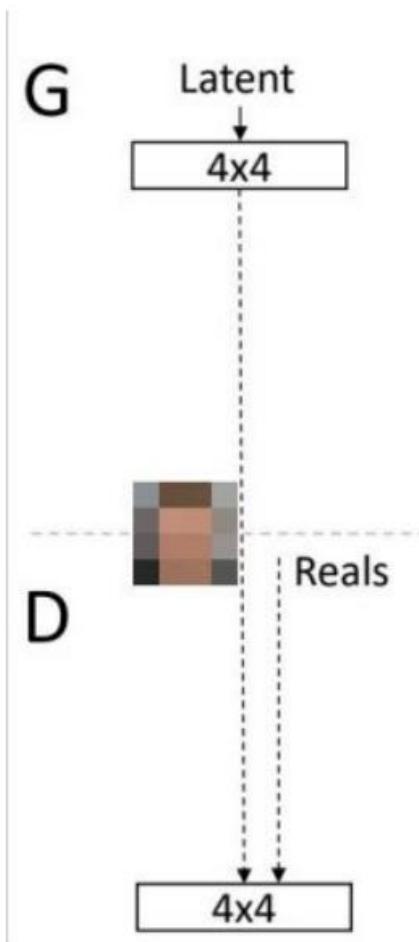


# Deep Convolutional GAN

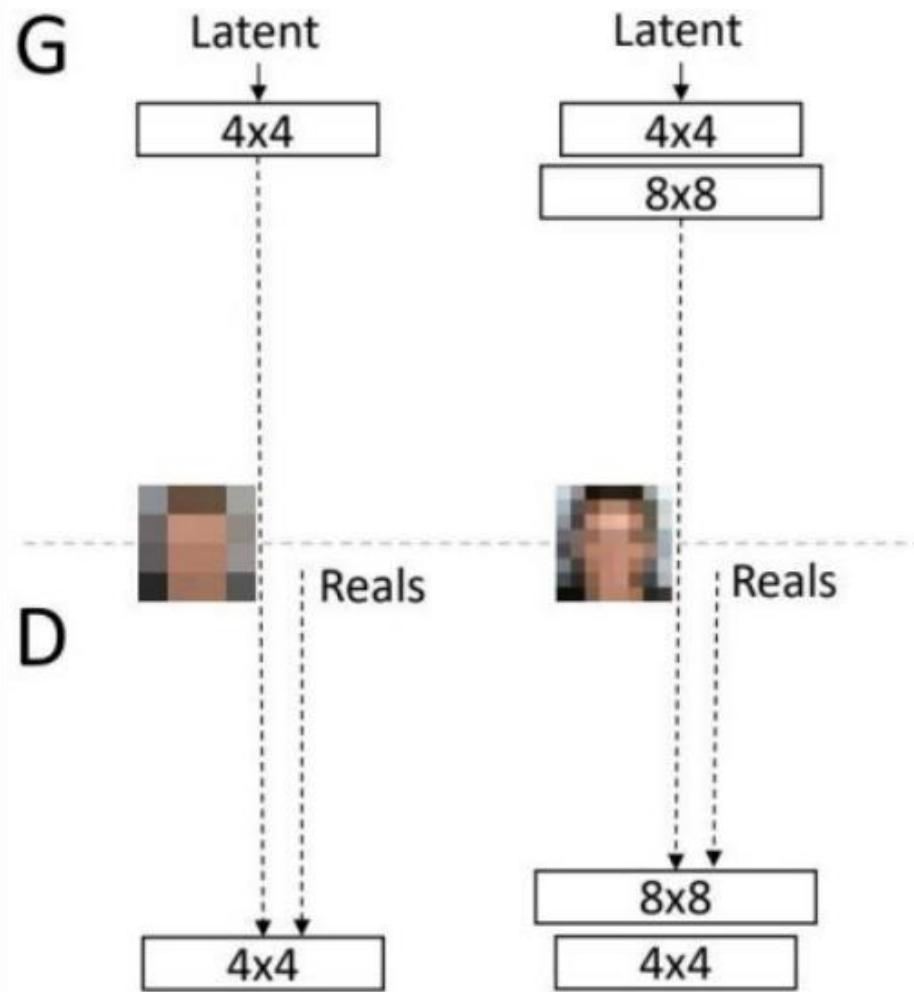
▪ نمایی از شبکه Discriminator



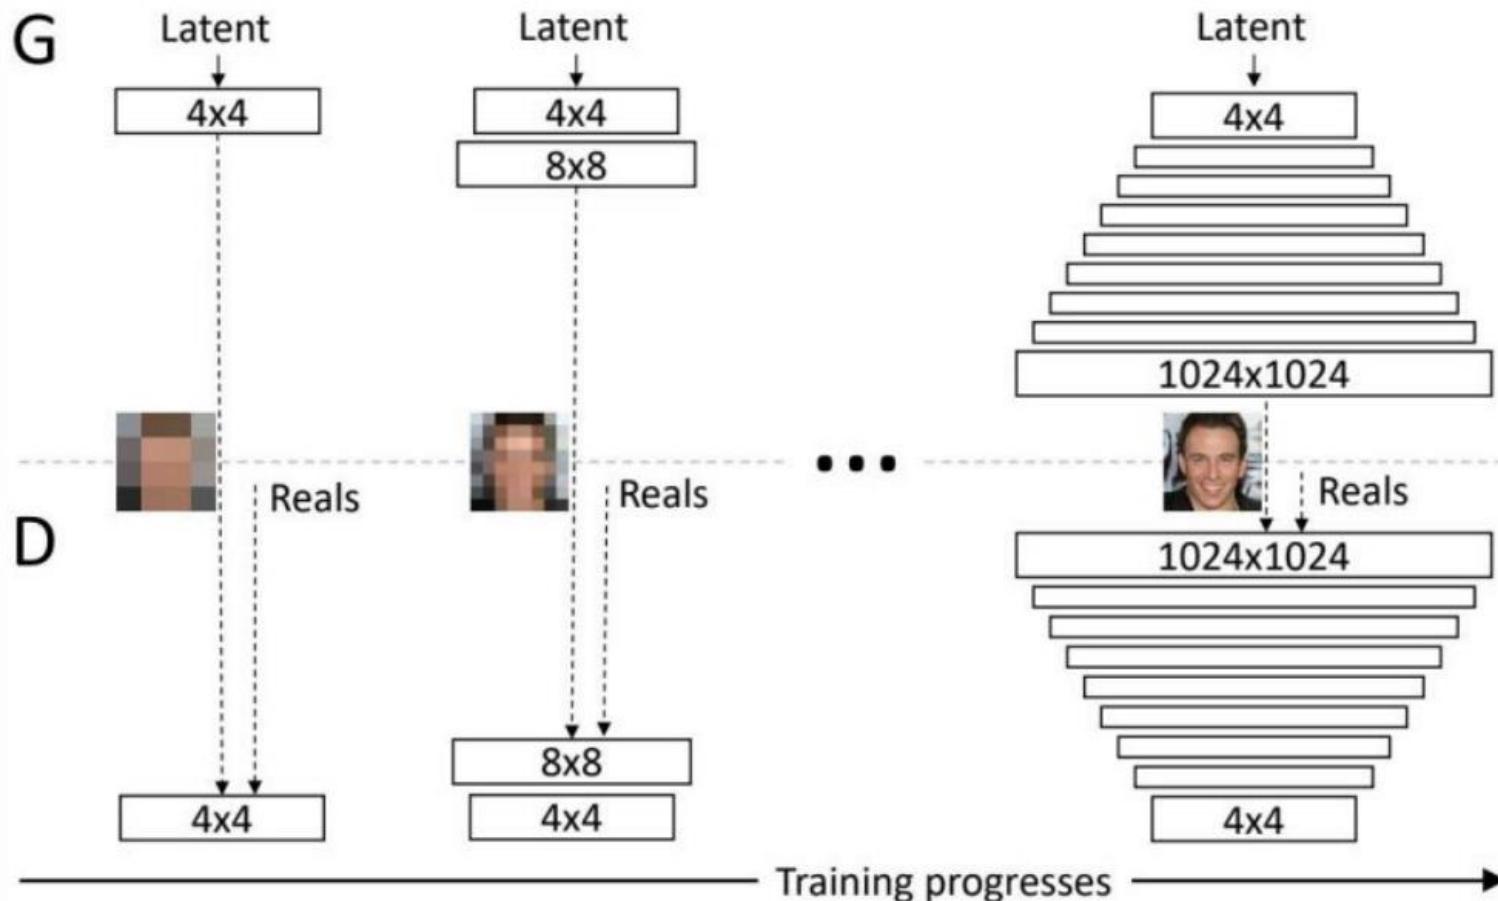
# Progressive Growing GAN



# Progressive Growing GAN



# Progressive Growing GAN



# مطالعات پیشین

## Brain

Reference	Object	Modalities	Network Type	Data Set
Myronenko et al. [67]	Brain	MRI	FCN	BRATS2018
Nie et al. [68]	Brain	MRI	3D FCN	Infant brain images
Wang et al. [69]	Brain	MRI	FCN	ANDI data set and NITRC data set
Borne et al. [70]	Brain	MRI	3D U-Net	62 healthy brain images
Casamitjana et al. [71]	Brain	MRI	V-Net	BRATS2017
Moeskops et al. [72]	Brain	MRI	GAN	MRBrainS13
Rezaei et al. [73]	Brain	MRI	cGAN	BRATS 2017
Giacomello et al. [74]	Brain	MRI	SegAN-CAT	BRATS2015, BRATS2019

## Eye

Reference	Object	Modalities	Network Type	Data Set
Leopold et al. [75]	Eye	Funduscopy	PixelBNN	DRIVE, STARE, CHASEDB1
Zhang et al. [76]	Eye	Funduscopy	U-Net	DRIVE, STARE, CHASEDB1
Jaemin et al. [77]	Eye	Funduscopy	GAN	DRIVE, STARE
Edupuganti et al. [78]	Eye	Funduscopy	FCN	Drishti-GS data set
Shankaranarayana et al. [79]	Eye	Funduscopy	FCN	RIM-ONE
Xiao et al. [46]	Eye	Funduscopy	Res-UNet	DRIVE

# مطالعات پیشین

## Cardiology

Reference	Object	Modalities	Network Type	Data Set
Tran et al. [87]	Left and right ventricles	MRI	FCN	SCD, LVSC, RVSC
Xu et al. [88]	The whole heart	CT	CFUN	MM-WHS2017
Dong et al. [89]	Left ventricles	3D echocardiography	VoxelAtlasGAN	60 subjects on 3D echocardiography
Zhang et al. [90]	Cardiac	MRI	LU-Net	ACDC Stacom 2017
Ye et al. [91]	The whole heart	CT	3D U-Net	MICCAI 2017 whole-heart
Xia et al. [92]	Left atrium	MRI	3D U-Net	LASC2018

## Abdomen

Reference	Object	Modalities	Network Type	Data Set
Christ et al. [84]	Liver	CT, MRI	FCN	3DIRCADb and other
Han et al. [85]	Liver	CT	DCNN	LiTS
Oktay et al. [49]	Pancreas	CT	Attention U-Net	TCIA
Yang et al. [60]	Liver	CT	DI2IN-AN	1000 CT volumes
Huo et al. [86]	Spleen	MRI	SSNet	60 clinically acquired abdominal MRI scans

# مطالعات پیشین

## Chest

Reference	Object	Modalities	Network Type	Data Set
Dai et al. [54]	Chest	CXR	SCAN	JSRT, Montgomery
Novikov et al. [81]	Chest	CXR	U-Net	JSRT
Anthimopoulos et al. [82]	Chest	CT	FCN	A data set of 172 sparsely annotated CT scans
Jue et al. [83]	Chest	CT, MRI	U-Net, dense-FCN	TCIA, NSCLC

## سایر اندام ها

Reference	Object	Modalities	Network Type	Data Set
Liu et al. [96]	Musculoskeletal	MRI	SegNet	MICCAI Challenge data set
Tran et al. [97]	Cell	Microscopic	SegNet	ALL-IDB1 database
Sekuboyina et al. [98]	Spines	CT	Btrfly Net	302 CT scans
Han et al. [99]	Spines	MRI	Spine-GAN	253 multicenter clinical patients
Milletari et al. [45]	Prostate	MRI	V-Net	PROMISE2012
Rundo et al. [30]	Prostate	MRI	USE-Net	three T2-weighted MRI data sets
kohl et al. [100]	Prostate	MRI	FCN	MRI images of 152 patients
Taha et al. [101]	Kidney	CT	Kid-Net	236 subjects
Izadi et al. [102]	Skin	Dermoscopy	GAN	DermoFit
Mirikharaji et al. [103]	Skin	Dermoscopy	FCN	ISBI 2017
Wang et al. [104]	Basal membrane	Histopathology	GAN	IPMCH

# مجموعه تصاویر پزشکی

Data Set	Modalities	Objects	URL
MSD	MRI, CT	Various	<a href="http://medicaldecathlon.com/">http://medicaldecathlon.com/</a>
BRATS	MRI	Brain	<a href="https://www.med.upenn.edu/sbia/brats2018/data.html">https://www.med.upenn.edu/sbia/brats2018/data.html</a>
DDSM	Mammography	Breast	<a href="http://www.eng.usf.edu/cvprg/Mammography/Database.html">http://www.eng.usf.edu/cvprg/Mammography/Database.html</a>
ISLES	MRI	Brain	<a href="http://www.isles-challenge.org/">http://www.isles-challenge.org/</a>
LiTS	CT	Liver	<a href="https://competitions.codalab.org/competitions/17094">https://competitions.codalab.org/competitions/17094</a>
PROMISE12	MRI	Prostate	<a href="https://promise12.grand-challenge.org/">https://promise12.grand-challenge.org/</a>
LIDC-IDRI	CT	Lung	<a href="https://wiki.cancerimagingarchive.net/display/Public/LIDC-IDRI">https://wiki.cancerimagingarchive.net/display/Public/LIDC-IDRI</a>
OASIS	MRI, PET	Brain	<a href="https://www.oasis-brains.org/">https://www.oasis-brains.org/</a>
DRIVE	Funduscopy	Eye	<a href="https://drive.grand-challenge.org/">https://drive.grand-challenge.org/</a>
STARE	Funduscopy	Eye	<a href="http://homes.esat.kuleuven.be/~mblaschk/projects/retina/">http://homes.esat.kuleuven.be/~mblaschk/projects/retina/</a>
CHASEDB1	Funduscopy	Eye	<a href="https://blogs.kingston.ac.uk/retinal/chasedb1/">https://blogs.kingston.ac.uk/retinal/chasedb1/</a>
MIAS	X-ray	Breast	<a href="https://www.repository.cam.ac.uk/handle/1810/250394?show=full">https://www.repository.cam.ac.uk/handle/1810/250394?show=full</a>
SCD	MRI	Cardiac	<a href="http://www.cardiacatlas.org/studies/">http://www.cardiacatlas.org/studies/</a>
SKI10	MRI	Knee	<a href="http://www.ski10.org/">http://www.ski10.org/</a>
HVS MR2018	CMR	Heart	<a href="http://segchd.csail.mit.edu/">http://segchd.csail.mit.edu/</a>

# معیارهای ارزیابی قطعه بندی

- در حوزه تصاویر پزشکی، توضیحات و تصاویر دستی پزشکان معمولاً بعنوان **gold standard** مورد استفاده قرار می‌گیرد. دیگر نتایج قطعه بندی مربوط به نتایج **prediction** هستند که بصورت **overlap**-**pixel-based** مورد بررسی قرار می‌گیرند.

## Dice Index ▪

- این ضریب برای ارزیابی شباهت (یا **overlap**) مورد استفاده قرار می‌گیرد در بازه عددی [۰...۱] قرار می‌گیرد و هر چه به یک نزدیکتر باشد نتیجه قطعه بندی بهتر است.

$$\text{Dice}(A, B) = 2 \frac{|A \cap B|}{|A| + |B|}$$

## Jaccard Index ▪

$$\text{Jaccard}(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

# معیارهای ارزیابی قطعه بندی

Rs تصاویر قطعه بندی شده  
توسط پزشک و Ts نتیجه  
الگوریتم قطعه بندی تصویر را  
نمایش می دهد

: تعداد پیکسل های که به اشتباه قطعه بندی شده اند Segmentation accuracy ▪

$$SA = \left( 1 - \frac{|R_s - T_s|}{R_s} \right) \times 100\%$$

: پیکسل هایی که به اشتباه توسط الگوریتم قطعه بندی بعنوان target شناسایی شده اند Oversegmentation accuracy ▪

$$OR = \frac{O_s}{R_s + O_s}$$

: پیکسل های که د. قطعه بند. ا: قلم افتاده اند Undersegmentation accuracy ▪

$$UR = \frac{U_s}{R_s + O_s}$$

# معیارهای ارزیابی قطعه بندی

Hausdorff distance ▪

- درجه شباهت بین مجموعه نقاط وزرا نشان می دهد (لازم به ذکر است وزرای دو مجموعه متفاوت تعلق دارند)

$$H = \left( \max_{i \in seg} \left( \min_{j \in gt} (d(i, j)) \right), \max_{j \in gt} \left( \min_{i \in seg} (d(i, j)) \right) \right)$$

# نتیجه گیری

- با وجود اینکه کاربرد هوش مصنوعی در تصاویر پزشکی پیشرفت زیادی داشته اما هنوز نتوانسته نیازهای کاربردهای واقعی را بطور کامل مرتفع کند
- چالش های تصاویر پزشکی
- پاتولوژی تصاویر پزشکی پیچیده و متنوع است متاسفانه متخصصان هوش مصنوعی آشنایی چندانی با کلینیک بیماران ندارند در مقابل پزشکان نیز آشنایی چندانی با تکنیک های هوشمند ندارند این مساله موجب ایجاد چالش هایی در همکاری بین این دو گروه می شود بنابراین هوش مصنوعی نمی تواند بصورت کارایی عمل کند به منظور به حداقل رسیدن کارایی، می بایست ارتباط میان متخصصان هوش مصنوعی و پزشکان توسعه یابد